

Geautomatiseerde documentatie generatie met behulp van Large Language Modellen: Het genereren van duidelijke overzichten en informatieve beschrijvingen voor ongedocumenteerde Python-projecten.

Max Milan.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Dhr. G. Bosteels

Co-promotor: Dhr. A. Pannemans

Academiejaar: 2023–2024

Eerste examenperiode

Departement IT en Digitale Innovatie .

**HO
GENT**

Woord vooraf

Toen ik aan de richting Toegepaste Informatica begon, wist ik meteen welke specialisatie ik wilde volgen. De keuze richting AI en Data Engineering sprak mij direct aan. Deze richting biedt mij de mogelijkheid aan om steeds nieuwe uitdagingen te vinden in alles wat ik doe.

Het aangaan van een uitdaging geeft mij de motivatie om steeds het beste van mezelf te geven. Zo was het ook een uitdaging om deze bachelorproef tot een goed einde te brengen. Een van de grootste uitdagingen was het werken met LLM's, aangezien dit de eerste keer was dat ik deze zelf implementeerde.

Daarom wil ik graag mijn co-promotor, Arne Pannemans, bedanken voor zijn onophoudelijke steun en waardevolle bijdragen. Zijn voortdurende aanwezigheid bij het geven van feedback en zijn kritische blik waren van onschatbare waarde voor het tot stand brengen van deze bachelorproef. Zijn continue steun en toewijding hebben mij geïnspireerd en gemotiveerd om het beste uit mezelf te halen. Dankzij zijn begeleiding heb ik mijn onderzoek naar een hoger niveau kunnen tillen.

Ook wil ik mijn promotoren meneer Gert-Jan Bosteels en mevrouw Lena De Mol bedanken voor hun kritische en waardevolle feedback. Deze feedback heeft ervoor gezorgd dat ik de juiste richting uitging en dat ik mijn ideeën helder kon verwoorden.

Tot slot zou ik graag mijn ouders en vrienden willen bedanken. Hun steun, voortdurende aanmoediging en begrip hebben mij door alle moeilijke momenten geholpen. Dankzij hen heb ik deze bachelorproef tot een goed einde kunnen brengen.

Samenvatting

Deze bachelorproef richt zich op het documenteren van ongedocumenteerde Pythonprojecten met behulp van een Large Language Model (LLM). Het genereren van duidelijk en overzichtelijke documentatie van een project helpt bij het begrijpen van de code en is de eerste stap in het delen van kennis. Bestaande tools hebben echter gedocumenteerde code nodig om documentatie te genereren. Het automatiseren van het documentatieproces zorgt ervoor dat dit geen manuele taak meer is.

De centrale onderzoeksvraag is: "Hoe kan geautomatiseerde documentatiegeneratie met behulp van Large Language Modellen (LLM) effectief worden toegepast op ongedocumenteerde Pythonprojecten om er duidelijke en overzichtelijke documentatie van te maken?" Deze vraag is verder opgesplitst in enkele deelvragen, wat is documentatie en wat is er nodig om een bestand en een project te documenteren? Met als doel een Proof of Concept (PoC) van een geautomatiseerde tool die de code van een Pythonproject analyseert en er documentatie van genereert.

Het onderzoek omvat enkele fases. Eerst wordt er gekeken hoe een enkel bestand gedocumenteerd kan worden. Vervolgens wordt er gekeken hoe verschillende bestanden in een project samen gedocumenteerd kunnen worden om zo een overzicht van het project te geven. De laatste fase beslaagd het evalueren van de tool door de documentatie van de tool te vergelijken met de handgeschreven documentatie van een project.

De resultaten van de evaluatie tonen aan dat de documentatie van de tool en de handgeschreven documentatie gelijkaardig zijn en door de visuele weergave van de relaties tussen de bestanden is de documentatie overzichtelijk en duidelijk. Er kunnen echter wel enkele fouten in de documentatie sluipen.

Deze studie biedt een oplossing voor het documenteren van ongedocumenteerde Pythonprojecten en kan gebruikt worden om de kennis van een project te delen met anderen.

Inhoudsopgave

Lijst van figuren	viii
Lijst van tabellen	ix
Lijst van codefragmenten	ix
1 Inleiding	1
1.1 Probleemstelling	1
1.2 Onderzoeksvraag	2
1.3 Onderzoeksdoelstelling	2
1.4 Opzet van deze bachelorproef	2
2 Stand van zaken	4
2.1 Wat is documentatie?	4
2.1.1 Bestand documentatie	5
2.1.2 Project documentatie	5
2.2 Bestaande documentatie tools	5
2.2.1 Doxygen	6
2.2.2 CodeCat	6
2.2.3 GPT4Docstrings	7
2.2.4 Sphinx	7
2.2.5 Pdoc	8
2.2.6 Samenvatting tools	8
2.3 Wat zijn Large Language Modellen (LLM)?	8
2.3.1 Transformers en de architectuur van LLM's	10
2.3.2 Trainen van LLM's	11
2.3.3 Fine-Tuning van LLM's	12
2.3.4 Prompt Engineering	12
2.3.5 Bestaande LLM's	13
3 Methodologie	16
3.1 Requirementsanalyse	17
3.1.1 Functionele requirements	17
3.1.2 Niet-functionele requirements	18
3.2 Opstellen van een short-list van bestaande tools	19

4 Resultaten	20
4.1 Bestand documentatie	20
4.1.1 Inleiding	20
4.1.2 Keuze van model	20
4.1.3 GPT4Docstrings tool	21
4.1.4 Abstract Syntax Tree	21
4.1.5 Docstrings	22
4.1.6 Prompting	22
4.1.7 Toevoegen van gegenereerde docstrings	26
4.1.8 Bestand samenvatting genereren	27
4.2 Project documentatie	29
4.2.1 Inleiding	29
4.2.2 Projectsamenvatting	29
4.2.3 Visualisatie van relaties tussen bestanden	31
4.3 Evaluatie	34
4.3.1 Inleiding	34
4.3.2 Bestandsdocumentatie evaluatie	34
4.3.3 projectdocumentatie evaluatie	35
5 Conclusie	39
A Onderzoeksvoorstel	41
A.1 Samenvatting	41
A.2 Introductie	42
A.3 Literatuurstudie	42
A.4 Methodologie	44
A.5 Verwacht resultaat, conclusie	45
B Bijlage	46
B.1 Prompts	46
B.1.1 Function Prompt 1	46
B.1.2 Function Prompt 2	47
B.1.3 Function Prompt 3	48
B.1.4 Class Prompt 1	50
B.1.5 Samenvatting van een bestand	52
B.1.6 Bestand zonder functies of klassen	53
B.1.7 Project samenvatting	54
B.1.8 Project samenvatting per file	54
B.2 Code	55
B.2.1 Vervangen van de code van een functie door de gegenereerde docstring. v1	55
B.2.2 Vervangen van de code van een functie door de gegenereerde docstring. v2	56

B.2.3	Vervangen van de code van een functie door de gegenereerde docstring. v3	56
B.2.4	Genereren van de relaties tussen de verschillende bestanden . .	57
B.2.5	Functies voor het samenvatting van een bestand	59
B.2.6	Generatie van een graph van de relaties tussen de bestanden. .	59
B.3	Zelfgedocumenteerde bestanden	61
B.3.1	Zelfgedocumenteerd bestand makkelijk niveau	61
B.3.2	Zelfgedocumenteerd bestand gemiddeld niveau	61
B.3.3	Zelfgedocumenteerd bestand moeilijk niveau	65
B.4	Python bestanden geclassificeerd op moeilijkheidsgraad.	67
B.4.1	Makkelijk	67
B.4.2	Gemiddeld	67
B.4.3	Moeilijk	70
B.4.4	Extreem moeilijk	70
B.5	Uitkomst documentatie van de Python bestanden	79
B.5.1	Uitkomst documentatie van gemiddeld bestand	79
B.6	Evaluatie bestand documentatie.	83
B.6.1	Uitkomst van bestand documentatie door eigen tool.	83
B.6.2	Zelfgedocumenteerd bestand gemiddeld niveau	87

Bibliografie**91**

Lijst van figuren

2.1	Voorbeeld diagram van Doxygen (Doxygen, 2023)	6
2.2	Uitkomst GPT4Docstrings	7
2.3	Artificiële intelligentie in lagen (Stöffelbauer, 2023)	9
2.4	Architectuur transformer model	11
2.5	Tokenisatie van tekst	12
3.1	Tijdslijn onderzoek	16
4.1	Voorbeeld van een project samenvatting	30
4.2	Voorbeeld van de documentatie van een bestand zonder functies of klassen	30
4.3	Voorbeeld van een graaf van de relaties tussen bestanden	34
4.4	Voorbeeld van een fragment van een graaf van de relaties tussen bestanden van een groot project	35
4.5	Evaluatie van de automatisch gegenereerde bestandsamenvatting met de zelfgedocumenteerde bestandsamenvatting. Voor het bestand AutoClicker van de Waegeneer (2022)	36
4.6	Vergelijking van de automatisch gegenereerde bestandsamenvatting met de zelfgedocumenteerde bestandsamenvatting.	36
4.7	Vergelijking van de automatisch gegenereerde docstring met de zelfgedocumenteerde docstring.	37
4.8	Vergelijking van de gegenereerde graaf met de handgetekende graaf.	38

Lijst van tabellen

2.1	Vergelijking documentatie tools	8
2.2	Overzicht van wat de tools kunnen genereren	8
2.3	Vergelijking van verschillende LLM's op basis van prijs (\$), context (aantal tokens) en snelheid (Tokens per seconde) (ArtificialAnalysis, 2024) .	14
2.4	Vergelijking LLM's op basis van beoordeling van menselijke evaluatie en MMLU (ArtificialAnalysis, 2024)	15
3.1	Requirementsanalyse	19
4.1	Aantal functies en klassen in de verschillende Python-bestanden.	26
4.2	Evaluatie van de documentatie van het project bmi-project van Simons (2019)	35

Lijst van codefragmenten

4.1	Voorbeeld uitkomst van GPT4Docstrings. (Pedrido, 2023)	21
4.2	Ophalen functies uit AST	22
4.3	Docstring van een functie	23
4.4	Prompt voor het genereren van een docstring voor een functie v1. . . .	24
4.5	Uitkomst prompt voor het genereren van een docstring voor een functie v2.	25
4.6	Uitkomst prompt voor het genereren van een docstring voor een klasse v4.	26
4.7	Code voor het vervangen van een docstring	27
4.8	Stuk uit uitkomst van het vervangen van de code van een functie B.5.1. . .	28
4.9	Code voor het vervangen van een docstring v2	28
4.10	Prompt voor het genereren van de relaties tussen de bestanden in een project, vervoledigd in bijlage B.2.4	33

1

Inleiding

In de wereld van softwareontwikkeling is documentatie een belangrijk onderdeel van een project. Documentatie is een manier om de code te beschrijven en te verklaren wat de code doet. Het is een manier om de code te begrijpen zonder dat de code zelf gelezen moet worden. Documentatie is belangrijk voor het onderhouden van een project, het delen van kennis en het begrijpen van de code.

Bestaande tools vergen gedocumenteerde code om de documentatie in andere formaten te genereren. Dit zorgt ervoor dat de code manueel gedocumenteerd moet worden. Een tool die dit automatisch kan doen, zorgt ervoor dat dit geen manuele taak meer is. Dit vergemakkelijkt het proces van het documenteren van een project en helpt met het vermijden van fouten die erin kunnen sluipen. In dit onderzoek wordt er gekeken hoe een enkel bestand gedocumenteerd kan worden en vervolgens hoe verschillende bestanden in een project samen gedocumenteerd kunnen worden om zo een overzicht van het project te geven. Zo krijgt de lezer een goed beeld van de documentatie van het project en kan het project gebruikt worden.

1.1. Probleemstelling

Projecten worden vaak niet goed gedocumenteerd, wat kan leiden tot problemen in de toekomst. Wanneer een andere persoon de code van een ongedocumenteerd project wil gebruiken moet de code volledig gelezen worden voordat er begrepen wordt wat de code doet. Dit is een tijdrovend proces en kan voorkomen worden door goede documentatie. Wanneer de code jaren later aangepast moet worden, is het ook handig om goede documentatie te hebben, zodat de persoon weet waar er aanpassingen moeten gebeuren. De skills en know-how van een project kunnen verloren gaan wanneer er geen documentatie is. Deze dienen juist gedeeld te worden met anderen zodat er geen dubbel werk gedaan moet worden.

Het is dus belangrijk dat er aan documentatie gedaan wordt en dat deze up-to-date blijft.

Er wordt gekeken naar een tool die automatisch de documentatie van een project kan genereren. Verder wordt er uitgelegd waarom een Large Language Model (LLM) gebruikt kan worden om de documentatie te genereren. Dit geeft de lezers de mogelijkheid om zich in te lezen in het project en erna zelf aanpassingen te maken of stukken code te gebruiken voor een ander project.

Python is een populaire programmeertaal die gebruikt wordt in de IT wereld. Volgens TIOBE (2024), een website die zoekpagina's afgaat en de populariteit van programmeertalen op basis van het aantal hits bepaalt, staat Python op de eerste plaats. Het is dus interessant om een tool te maken die Python-projecten kan documenteren.

1.2. Onderzoeksvraag

Hoe kan geautomatiseerde documentatiegeneratie met behulp van Large Language Modellen (LLM) effectief worden toegepast op ongedocumenteerde Python-projecten om er duidelijke en overzichtelijke documentatie van te maken?

- Wat is documentatie?
- Wat zijn de huidige documentatie tools?
- Wat is er nodig om de code van een bestand te documenteren?
- Wat is er nodig om de code van een project te documenteren?
- Waarom documentatie met behulp van een LLM?
- Hoe wordt de documentatie zo goedkoop mogelijk gehouden?

1.3. Onderzoeksdoelstelling

Het eindresultaat van deze bachelorproef is een Proof of Concept (PoC) van een geautomatiseerde tool die de code van een Python-project analyseert en er documentatie van genereert. De gegenereerde documentatie laat het toe het project te begrijpen.

1.4. Opzet van deze bachelorproef

De volgende hoofdstukken van deze bachelorproef zijn als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein op basis van een literatuurstudie.

In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.

In Hoofdstuk 4 worden de resultaten van het onderzoek besproken voor bestand-documentatie en projectdocumentatie. In het verdere verloop van dit onderzoek wordt er gekeken naar de evaluatie van de gegenereerde documentatie.

In Hoofdstuk 5, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek binnen dit domein.

2

Stand van zaken

In dit hoofdstuk wordt de literatuurstudie besproken. Door deze literatuurstudie is het mogelijk om een beter inzicht te krijgen in de technologie en mogelijkheden voor de documentatie van Python-projecten alsook hoe het toegepast kan worden met behulp van Large Language Modellen. Er zal nadruk worden gelegd op bestaande literatuur en onderzoeken die verbonden zijn met documentatie van Python-projecten. In dit onderdeel zullen verschillende hoofdstukken worden aangekaart. Als eerste zal er duidelijk gemaakt worden wat er juist verstaan wordt onder documentatie. Vervolgens wordt er gekeken naar bestaande documentatie tools. In het derde deel van deze literatuurstudie wordt er gekeken wat Large Language Modellen zijn, hoe deze werken en wat enkele bestaande modellen zijn.

2.1. Wat is documentatie?

Alvorens dieper op het onderwerp in te gaan, is het belangrijk dat er een duidelijk beeld gevormd wordt wat documentatie is. Waarom is documentatie belangrijk voor een project en wat wordt er begrepen onder documentatie?

Documentatie is het proces van het vastleggen van de werking van een project. Volgens Code Quality (2024) kan dit op verschillende manieren gebeuren. Er kan gekozen worden om de documentatie te schrijven in de vorm van een commentaar in de code, een docstring, een API voor klassen of functies of in de vorm van een README.md bestand (Code Quality, 2024). Het doel van documentatie is om de werking van het project te beschrijven zodat andere programmeurs het project kunnen begrijpen en gebruiken. Zo gaat er geen tijd verloren aan het lezen van de code en het begrijpen ervan.

Documentatie kan gemaakt worden voor verschillende doelgroepen. Het kan voor interne of externe doeleinden zijn. Interne documentatie is voor documentatie binnen hetzelfde bedrijf. Dit gaat dan om het capteren van de proces kennis die ver-

gaard is binnen een project. Dit is informatie zoals een roadmap of product requirements. Deze documentatie gaat over het vastleggen van gedetailleerde uitleg over hoe iets werkt en hoe het onderhouden kan worden (swimm.io, 2024).

Externe documentatie is voor documentatie die gedeeld wordt met andere bedrijven of klanten. Dit gaat dan over de basiswerking van de code van een project zodat andere programmeurs het kunnen gebruiken. Gebruiksaanwijzingen of handleidingen zijn ook een vorm van externe documentatie (swimm.io, 2024).

Voor deze bachelorproef wordt er gekeken naar het documenteren van een Python-project in de vorm van commentaar in de code en het genereren van een samenvattend document van het gehele project. Omdat Python een populaire programmeertaal is volgens TIOBE (2024) en er veel projecten in deze taal geschreven worden, is het interessant om te kijken hoe deze projecten gedocumenteerd kunnen worden. Ook kan er in de code bij functies aan type hinting gedaan worden. Dit indiceert wat de datatypes van de input en output van een functie zijn (Bailey, 2024). Uit deze documentatie kan de werking van het project duidelijk worden en kunnen de relaties tussen de verschillende bestanden en functies weergegeven worden. In het verdere verloop van deze bachelorproef wordt er gekeken hoe de documentatie van een Python-project gegenereerd kan worden.

2.1.1. Bestand documentatie

Eerst dienen de bestanden van het project gedocumenteerd te worden. Dit gebeurt door de code van het bestand te analyseren en de docstrings van de verschillende functies en klassen te genereren.

Docstrings of documentatie strings worden aan het begin van een functie of klasse geplaatst. Deze strings worden gebruikt om de functie of klasse te documenteren (GeeksforGeeks, 2023). Volgens GeeksforGeeks (2023) zijn docstrings vitaal in het overdragen van het doel en de werking van een functie of klasse.

Deze docstrings kunnen dan gebruikt worden om een samenvatting van het bestand te genereren.

2.1.2. Project documentatie

De documentatie van het project wordt gemaakt door de samenvattingen van de verschillende bestanden te combineren. Deze samenvattingen worden gegenereerd op basis van de samenvatting van de bestanden die tot het project behoren. In deze samenvatting behoort de werking van het project, de verschillende bestanden met functies en klassen en de relaties tussen deze bestanden.

2.2. Bestaande documentatie tools

Voor er gekeken wordt hoe LLM's mogelijk gebruikt kunnen worden voor het genereren van documentatie is het belangrijk dat er een helder beeld is van de huidige tools die gebruikt worden voor het genereren van documentatie. De documenta-


```
1 class A:
2     def __init__(self, a: int, b: int):
3         self.a = a
4         self.b = b
5
6     def sum(self):
7         return self.a + self.b
```

(a) Voorbeeld code zonder docstrings van Pedrido (2023)

```
1 class A:
2     """A class representing an object with two integer attributes.
3
4     Attributes:
5         a (int): The first integer attribute.
6         b (int): The second integer attribute.
7     """
8     def __init__(self, a: int, b: int):
9         self.a = a
10        self.b = b
11
12    def sum(self):
13        """Calculates the sum of the two integer attributes.
14
15        Returns:
16            int: The sum of the two integer attributes.
17        """
18        return self.a + self.b
```

(b) Voorbeeld code met docstrings van Pedrido (2023)

Figuur 2.2: Voorbeeld uitkomst van de tool van Pedrido (2023)

2.2.3. GPT4Docstrings

De tool van Pedrido (2023) genereert docstrings voor Python code. Het maakt gebruik van GPT-4 (OpenAI, 2023) om de docstrings te genereren. Deze tool leunt sterk aan bij de doelstelling van deze bachelorproef, namelijk het genereren van documentatie met behulp van LLM's. Het nader bekijken van deze tool kan een meerwaarde zijn voor deze bachelorproef.

Zo gebruikt GPT4Docstrings van Pedrido (2023) de Abstract Syntax Tree (AST) van de code om de structuur van de code te begrijpen. Uit de AST kunnen de juiste stukken code gehaald worden om de docstrings te genereren. Dit kan goed van pas komen voor het genereren van documentatie van Python-projecten. Een voorbeeld van deze tool kan gezien worden in figuur 2.2.

2.2.4. Sphinx

Sphinx van Sphinx Team (2023) is één van de meest gebruikte tools voor het genereren van documentatie voor Python-projecten. Het genereert documentatie aan de hand van docstrings. Het toont de hiërarchie van het project om een duidelijk overzicht te geven. Deze tool is vrij flexibel want het kan uitgebreid worden met verschillende extensies, zodat het alle mogelijke wensen kan vervullen. Volgens Sphinx Team (2023) kan de extensie autodoc semi-automatisch de docstrings van een module extraheren en in de documentatie plaatsen. Dit is handig wanneer de automatische documentatie generatie van een geheel project gewenst is. Zo kan het project samengevat worden aan de hand van de docstrings van de verschillende python files. Alvorens een Python-project gedocumenteerd kan worden met Sphinx (Sphinx Team, 2023) dienen alle bestanden aangevuld te worden met doc-

strings. Dit gebeurt echter niet bij het runnen van het programma.

2.2.5. Pdoc

Pdoc (Gallant & Hils, 2023) genereert documentatie in de vorm van een website die een API van de documentatie bevat. Hier kan er eenvoudig op de website gezocht worden naar een functie of klasse met de bijhorende documentatie.

Tool	programmeertaal	type
Doxygen	C++, C, Python, PHP, Java	HTML, PDF, markdown
CodeCat	JavaScript	docstring
Sphinx	Python	HTML, LATEX, man pages
Pdoc	Python	API
GPT4Docstrings	Python	docstring

Tabel 2.1: Vergelijking documentatie tools

2.2.6. Samenvatting tools

Door de verschillende tools op te lijsten en te vergelijken met elkaar wordt er een duidelijk beeld gevormd wat de tools kunnen genereren. Zo kan er een keuze gemaakt worden welke tool het beste past bij dit onderzoek. In tabel 2.2 wordt er een overzicht gegeven wat de tools kunnen genereren. De tools Doxygen, Sphinx en Pdoc kunnen enkel een document genereren in de vorm van een website of een bestand op basis van reeds bestaande docstrings en commentaren in de code. De tool GPT4Docstrings genereert docstrings voor Python code met behulp van een LLM.

Tool	docstrings	samenvatting bestand	samenvatting project	visualisatie
GPT4Docstrings	ja	nee	nee	nee
Doxygen	nee	nee	nee	ja
Sphinx	nee	nee	nee	nee
Pdoc	nee	nee	nee	nee

Tabel 2.2: Overzicht van wat de tools kunnen genereren

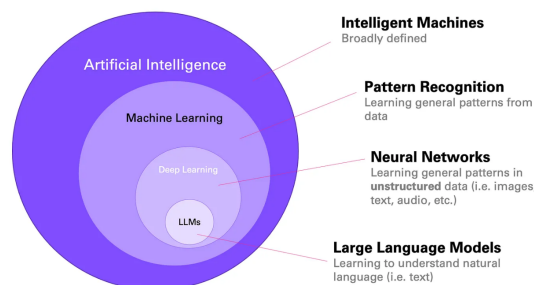
2.3. Wat zijn Large Language Modellen (LLM)?

Uit de vorige sectie is gebleken dat er slechts één tool geschikt is voor het genereren van documentatie voor projecten zonder gedocumenteerde code. De tool GPT4Docstrings van Pedrido (2023) maakt gebruik van een Large Language Mo-

del (LLM) om de docstrings te genereren. Het is dus belangrijk dat er een duidelijk beeld is van wat LLM's juist zijn en hoe deze werken. Wat kunnen deze modellen, wat zijn de mogelijke beperkingen en wat is de huidige stand van zaken. In dit hoofdstuk wordt er een antwoord gegeven op de vragen:

- Bestaan er LLM's speciaal getraind op Python code?
- Kunnen LLM's gebruikt worden om documentatie te genereren?

Dit draagt bij tot het verkrijgen van een grondige basiskennis van LLM's. Het veld waarin AI zich bevindt, wordt vaak voorgesteld volgens figuur 2.3. Het bestaat uit verschillende cirkels met elk een eigen laag volgens Stöffelbauer (2023). Deze lagen zijn: Artificial Intelligence, Machine Learning, Deep Learning en Large Language Modellen. Omdat LLM's een subveld zijn van Deep Learning is het belangrijk dat er een duidelijk beeld is van wat Deep Learning juist is. Uit de figuur 2.3 blijkt dat AI verschillende categorieën omvat. Volgens Stöffelbauer (2023) is AI een brede term wat vaak verwijst naar slimme machines. Machine Learning (ML) is een subveld van AI, waarin patronen worden herkend tussen een input en een output. ML kan gebruikt worden voor verschillende taken zoals classificatie, regressie, clustering en dergelijke. Volgens Stöffelbauer (2023) is Deep Learning (DL) een subveld van ML, waarin complexe algoritmen en Deep Neural Networks gebruikt worden om complexere taken uit te voeren. Deep Learning is een krachtige tool die gebruikt wordt voor verschillende taken zoals: beeldherkenning, spraakherkenning, ...



Figuur 2.3: Artificiële intelligentie in lagen (Stöffelbauer, 2023)

Large Language Modellen zijn geavanceerde AI-systemen die dienen om menselijke taal te verstaan, te genereren en te verwerken. LLM's worden getraind op een grote hoeveelheid tekst wat vaak uit allerlei data zoals artikels of websites gehaald wordt. Volgens Beelen (2023) zorgen Deep Neural Networks ervoor dat LLM's natuurlijke taal verwerken op een gelijkaardige manier die vergelijkbaar is met de menselijke taalvaardigheid. Deze hebben een grote vooruitgang gekend in 2017 door de paper van Vaswani e.a. (2017). Hieruit kwam een nieuw mechanisme tot stand namelijk transformers wat bestaat uit Attentie blokken. Enkele voordelen die komen kijken bij het gebruiken van transformers zijn:

- Het kan lange sequenties verwerken.
- Het kan parallel sequenties verwerken.
- Het kan de relaties tussen de verschillende delen van de sequentie leren.

Hierdoor hebben transformer modellen een snellere trainingsperiode dan vorige neurale netwerken ("What are the primary advantages of transformer models?", 2023).

2.3.1. Transformers en de architectuur van LLM's

Omdat in dit onderzoek gebruik gemaakt wordt van LLM's is het nodig dat er dieper ingegaan wordt op de architectuur van deze modellen om een beter inzicht te krijgen hoe deze werken. Een neuraal netwerk bestaat uit verschillende lagen. Enkele belangrijke blokken die gebruikt worden binnen de transformer laag zijn:

- Self-Attention
- Cross-Attention
- Masked Self-Attention

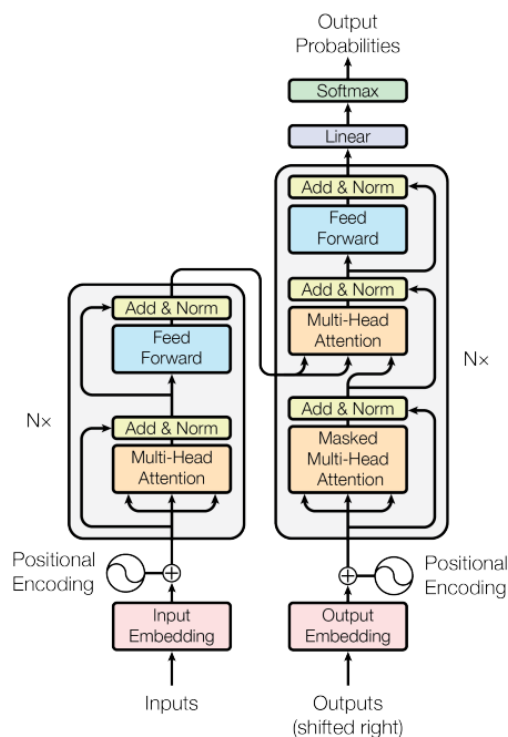
Deze Attentie blokken worden gebruikt in de encoder en decoder van een transformer en stromen voort uit het onderzoek van Vaswani e.a. (2017).

Transformers zijn een speciaal type van neurale netwerken die gebruik maken van verschillende Attentie blokken. Attentie is een mechanisme dat gebruikt wordt om de relaties tussen verschillende delen van de invoersequenties te leren. Een transformer bestaat uit een encoder en een decoder. Niet elke transformer bestaat uit zowel een encoder als een decoder het kan ook enkel encoder of decoder bevatten (Hoque, 2023). De encoder wordt gebruikt om de invoersequenties te verwerken en de decoder wordt gebruikt om de uitvoersequenties te genereren. Zo is BERT van Devlin e.a. (2019) een transformer die enkel een encoder heeft en GPT van Radford e.a. (2018) heeft enkel een decoder. De transformer architectuur uit de paper van Vaswani e.a. (2017) kan gezien worden in figuur 2.4.

Self-Attention duidt dynamische gewichten toe aan verschillende elementen binnen de meegegeven sequentie, bijvoorbeeld bij woorden in een zin. Dit laat het model toe om zich te concentreren op de meest relevante delen van de invoer, terwijl de invloed van minder cruciale delen wordt verminderd. De invoersequentie wordt eerst in drie verschillende vectoren omgezet: Query, Key en Value. De Query vector stelt een specifiek token uit de invoersequentie voor. De Key vector vertegenwoordigt alle tokens en de vector voor Value bevat de feitelijke inhoud die aan elk token is gekoppeld. De similariteit tussen de Query en de Key vector wordt berekend aan de hand van het inwendig product van de twee vectoren. Deze similariteit wordt gebruikt om de gewichten te berekenen die aan de Value vector worden toegekend (Vaswani e.a., 2017).

Masked Self-Attention is een variant van Self-Attention die gebruikt wordt in de decoder van een transformer. In de decoder wordt er een mask gebruikt om enkel de vorige tokens te zien in de sequentie (Vaswani e.a., 2017). Dit vermijdt dat er informatie van de toekomstige tokens gebruikt wordt. Zo kan de transformer niet "vals spelen" tijdens het train proces.

Cross-Attention is een variant van Self-Attention die gebruikt wordt in de decoder van een transformer. Deze laag gebruikt de informatie van de encoder en de vorige Attentie laag van de decoder om de uitvoersequenties te genereren. De Query vector is de uitvoer van de vorige Attentie/Cross-Attention laag van de decoder en de Key en Value vector zijn de uitvoer van de encoder (Vaswani e.a., 2017). Doordat de Cross-Attention laag informatie van zowel de encoder als decoder krijgt, kan het model de relaties tussen de verschillende delen van de invoersequenties leren. Deze relaties worden dan gebruikt om de uitvoersequenties te genereren.



Figuur 2.4: Transformer model architectuur (Vaswani e.a., 2017)


2.3.2. Trainen van LLM's

Het trainen van LLM's is een complex proces dat veel tijd en rekenkracht vereist. Dit gebeurt in verschillende stappen. De eerste fase begint bij het verzamelen van een grote hoeveelheid tekst die gebruikt wordt om het model te trainen. Deze tekst wordt gehaald uit verschillende artikelen, websites, boeken en andere bronnen.

Zo kan het volgende woord in een sequentie van tekst voorspeld worden.

Het model krijgt deze grote hoeveelheid tekst in de pre-training fase. In deze fase

leert de LLM grammatica, semantiek, taal patronen en factuele informatie (Cacic, 2023). Voordat de data meegegeven wordt aan het model moet de data gecleaned en geformatteerd worden. Dit gebeurt in het tokenization proces. Hier wordt de tekst omgezet in tokens die het model kan verwerken 2.5. Woorden kunnen kleiner gemaakt worden zodat de volledige tekst in het model past. Dit gebeurt wanneer het model een beperkte input capaciteit heeft (ElHousieny, 2023). Deze woorden worden dan omgezet in embeddings en deze embeddings worden meegegeven aan het model om het te trainen. Uit de data kunnen dan patronen gehaald worden met behulp van Transformers 2.3.1, maar het is nog niet in staat om vragen of instructies te begrijpen.



Figuur 2.5: Gesimplificeerde tokenisatie van tekst (TeeTracker, 2023)

De volgende fase bestaat uit het trainen van het model op een dataset met instructies en het antwoord erop. Volgens Das (2024) is dit het gesuperviseerde Fine-Tunen van een LLM. In deze fase probeert het model de patronen te leren die nodig zijn om vragen te beantwoorden of instructies te volgen. Dit zorgt ervoor dat het model instructies kan volgen en vragen leert te beantwoorden.

Er kan gebruik gemaakt worden om het model specifiek aan de wensen van de mens te laten voldoen. Dit kan door het gebruiken van Reinforcement Learning met menselijke feedback (Lambert e.a., 2022). Hierbij geeft de mens feedback aan het model en leert het model bij door deze feedback.

2.3.3. Fine-Tuning van LLM's

Volgens Peckham e.a. (2024) kan het model achteraf nog extra getraind worden op een specifieke dataset zoals Python code of medische data. Dit proces heet het Fine-Tunen van een LLM. Een vereiste voor het Fine-Tunen van een LLM is dat de dataset een grote hoeveelheid data moet hebben. Ook moet de dataset van hoge kwaliteit zijn en moet de dataset het onderwerp representatief voorstellen (Peckham e.a., 2024).

2.3.4. Prompt Engineering

Prompt Engineering is een techniek die gebruikt wordt om de uitkomst van een LLM te beïnvloeden volgens Google (2023). Er wordt een prompt gegeven aan het model met duidelijke instructies over wat er verwacht wordt. Wanneer deze instructies niet voldoen, wordt de prompt iteratief aangepast en wordt de uitkomst geëvalueerd totdat de gewenste uitkomst is bereikt. Dit iteratieve proces heet

Prompt Engineering (Trad e.a., [2024](#)).

Door het toevoegen van enkele voorbeelden aan de prompt kan het model beter begrijpen wat er verwacht wordt (OpenAi, [2024b](#)).

- Geef structuur aan de prompt.
- Geef een rol mee.
- Geef een context.
- Geef een doel.

Dit zijn de beste manieren om een prompt te structureren volgens (Google, [2023](#)).

2.3.5. Bestaande LLM's

Momenteel zijn er verschillende LLM's die gebruikt worden voor verschillende taken. Deze LLM's zijn getraind op verschillende datasets en hebben verschillende architecturen. Het is belangrijk dat er een duidelijk beeld is van de verschillende LLM's en hun mogelijkheden. Met dit beeld kan er een goede keuze gemaakt worden voor het genereren van documentatie.

Eén van de grote spelers in de wereld van LLM's is OpenAI. OpenAI heeft verschillende LLM's ontwikkeld gaande van GPT (Radford e.a., [2018](#)) tot GPT-4 (OpenAI, [2023](#)). Het is getraind op een grote hoeveelheid data en heeft een grote capaciteit. Een nadeel is dat GPT-4 een betalende service is (OpenAI, [2023](#)).

Een andere grote speler is Google. Google heeft verschillende LLM's ontwikkeld waaronder BERT van Devlin e.a. ([2019](#)) en Gemini (Google, [2024](#)). BERT staat voor Bidirectional Encoder Representations from Transformers, een DL model waar elk output element verbonden is met elk input element (Hashemi-Pour & Lutkevich, [2024](#)). BERT was een eerste stap in de wereld van LLM's voor Google. Sinds kort heeft Google ([2024](#)) een nieuwe LLM ontwikkeld genaamd Gemini. Deze LLM is een sterke concurrent voor GPT-4 van OpenAI ([2023](#)).

Google (Google, [2024](#)) bracht een model met verschillende versies uit: Gemini Pro, Gemini Ultra en Gemini Nano. Elke versie is gemaakt voor een specifiek doel. Zo is Gemini Nano het meest efficiënte model voor mobiele toestellen, terwijl Gemini Pro het beste model is voor het schalen van allerlei taken. En Gemini Ultra is het meest capabele en grootste model van Google. Dit kan gebruikt worden voor complexe taken. Een van de voordelen van Gemini is dat er een groot aantal input tokens meegegeven kunnen worden, namelijk 1 miljoen tokens (Google, [2024](#)). Dit is aanzienlijk meer dan de 128 duizend tokens van GPT-4.

Een derde speler in de wereld van LLM's is Meta. Meta heeft verschillende LLM's ontwikkeld onder de naam LLama 2 (Meta, [2024](#)). De LLama 2 familie bestaat uit verschillende LLM's die getraind zijn op verschillende data. Sommige zijn extra getraind voor specifiekere doeleinden. Zo is er bijvoorbeeld een LLM getraind op Python code, genaamd Code LLama 2 van Rozière e.a. ([2024](#)). Een voordeel van de

LLama 2 familie is dat deze LLM's open sourced zijn en dus voor iedereen toegankelijk zijn.

Antropic heeft ook een LLM ontwikkeld genaamd Claude (Anthropic, 2023). Claude's capaciteiten zijn code generatie, het verstaan van meerdere talen, beelden analyseren en kan geavanceerde redeneringen geven. Er bestaan 3 versies van Claude: Haiku, Sonnet en Opus. Haiku is een lichte versie van Claude en Sonnet is de combinatie van performantie en snelheid. Opus is het intelligentste model dat complexe taken kan uitvoeren en begrijpen. Claude is een betalende service en de prijzen zijn afhankelijk van de gekozen versie van Claude (Anthropic, 2023).

De verschillen tussen deze LLM's zijn groot. Zo is er een verschil in capaciteit, trainingsdata en toegankelijkheid. Het is belangrijk dat er een goede keuze gemaakt wordt voor het genereren van documentatie. Deze keuze zal afhangen van de mogelijkheden van de LLM's en de doeleinden van de documentatie.

Model	Input (1M tokens)	Output (1M tokens)	Context	Snelheid (t/s)
GPT-4 Turbo (OpenAi, 2024a)	\$10.00	\$30.00	128k	18
GPT-4 (OpenAi, 2024a)	\$30.00	\$60.00	128k	21
GPT-3.5 Turbo (OpenAi, 2024a)	\$0.50	\$1.50	16k	52
Gemini 1.5 Pro Google (2024)	\$3.50	\$10.50	128k	52
Code LLama (Meta, 2024)	\$0.90	\$0.90	100k	34
LLama 2 (Meta, 2024)	\$0.95	\$1.00	100k	34
Claude Opus (Anthropic, 2023)	\$15.00	\$75	200k	29
Claude Sonnet (Anthropic, 2023)	\$3.00	\$15	200k	61
Claude Haiku (Anthropic, 2023)	\$0.20	\$1.20	200k	102

Tabel 2.3: Vergelijking van verschillende LLM's op basis van prijs (\$), context (aantal tokens) en snelheid (Tokens per seconde) (ArtificialAnalysis, 2024)

In de tabel 2.3 wordt er een vergelijking gemaakt tussen verschillende LLM's. Hierin wordt er gekeken naar de prijs van de input en output tokens, de grootte van de context en het aantal tokens dat per seconde verwerkt kan worden.


In de tabel 2.4 wordt een vergelijking gemaakt tussen verschillende LLM's tussen twee kolommen. De eerste kolom bevat de beoordeling van de coding mogelijkheden van het model gequoteerd met menselijke evaluatie. In de tweede kolom staat de quoterings op basis van de MMLU een dataset opgesteld door Hendrycks e.a. (2020). MMLU staat voor het meten van de multitask taalbegrip capaciteiten van een model (Hendrycks e.a., 2020). Beide kolommen staan uitgedrukt in procenten met 100% als maximum. Hieruit kan geconcludeerd worden dat GPT-4 en GPT-4 Turbo de beste scores behalen op beide vlakken. Maar omdat er in dit onderzoek gezocht wordt naar een goedkope oplossing wordt er geconcludeerd uit beide tabellen dat GPT-3.5 Turbo de beste prijs/kwaliteit verhouding heeft.

Model	Coding	Beredenering en Kennis
GPT-4 Turbo (OpenAi, 2024a)	86%	85.4%
GPT-4 (OpenAi, 2024a)	86%	88.4%
GPT-3.5 Turbo (OpenAi, 2024a)	70%	73.2%
Gemini 1.5 Pro Google (2024)	82%	71.9%
Code LLama (Meta, 2024)	/	67.8%
LLama 2 (Meta, 2024)	69%	/
Claude Opus (Anthropic, 2023)	87%	/
Claude Sonnet (Anthropic, 2023)	79%	/
Claude Haiku (Anthropic, 2023)	75%	/

Tabel 2.4: Vergelijking LLM's op basis van beoordeling van menselijke evaluatie en MMLU (ArtificialAnalysis, [2024](#))

3

Methodologie



Figuur 3.1: Tijdslijn onderzoek

Het onderzoek is in vier fases opgedeeld. De eerste fase omvat de literatuurstudie. In deze literatuurstudie wordt er onderzocht wat de huidige stand van zaken is omtrent de technologie en mogelijkheden voor de documentatie van Python-projecten met behulp van Large Language Modellen. Zo wordt er gekeken wat LLM's zijn, hoe ze werken en wat bestaande tools zijn voor het genereren van documentatie.

Nadat er een duidelijk beeld gevormd is over de stand van zaken, kan er begonnen worden aan de tweede fase. Hierin wordt er een tool ontwikkeld die een Python-bestand kan analyseren op basis van de ongedocumenteerde code van het bestand. Eerst wordt er per functie en per klasse een docstring gegenereerd. Deze kunnen gebruikt worden voor het genereren van een samenvatting van het bestand. Wat op zijn beurt gebruikt kan worden om een samenvatting van het project te genereren in de volgende fase. De uitkomst van deze fase is een tool die de documentatie van een Python-bestand kan genereren. Door aan prompt engineering te doen, met het prompt dat meegegeven wordt aan de LLM, kunnen de bekomen docstrings accurater worden. Verder wordt er gekeken hoe de documentatie van Python functies gebruikt kan worden voor het maken van een gehele samenvatting van het project. Dit wordt gedaan op basis van huidige methoden om docstrings aan te maken en te gebruiken. Daarna kunnen de verschillende

docstrings met de bijhorende naam van de functie of klasse gebruikt worden om een samenvatting te genereren. Deze informatie kan dan gegeven worden aan de Large Language Modellen om een samenvatting te genereren.

De derde fase beslaagt het documenteren van een geheel project. Door de vorige fases te combineren, het documenteren van de individuele bestanden en het genereren van een samenvatting van het project, kan er een tool gemaakt worden die de documentatie van een geheel project kan genereren. Deze documentatie bestaat uit de individuele documentatie van de bestanden en een samenvatting van het gehele project. Alsook wordt er gekeken hoe de relaties tussen de verschillende bestanden gevisualiseerd kunnen worden.

De laatste fase is het evalueren van de tool. Hier wordt er gekeken naar de kwaliteit van de documentatie die de tool genereert. Dit wordt gedaan door de documentatie van de tool te vergelijken met de handgeschreven documentatie van een project. Deze vergelijking gebeurt eerst voor een bestand en daarna voor een project.

3.1. Requirementsanalyse

De requirementsanalyse is een belangrijk onderdeel van het onderzoek. Hier wordt er gekeken wat de tool moet kunnen en wat de verwachtingen zijn van de tool.

3.1.1. Functionele requirements

Should Have:

- De tool moet in staat zijn om docstrings te genereren voor functies en klassen voor een Python-bestand.
De tool genereert docstrings voor functies en klassen in een Python-bestand. Dit gebeurt door de code te analyseren en op basis daarvan een docstring te genereren.
- De tool moet in staat zijn om een samenvatting van een Python-bestand te genereren.
De tool maakt een samenvatting van een Python-bestand. In deze samenvatting zitten de belangrijkste zaken van het bestand zijnde de functies en klassen die erin voorkomen en wat deze doen, alsook hun eventuele parameters en de uitkomst.
- De tool moet in staat zijn om een samenhangende samenvatting van een Python-project te genereren.
De tool dient een samenvatting te maken van een Python-project. Deze samenvatting bestaat uit de individuele samenvattingen van de bestanden en een overkoepelende samenvatting van het project. Hierin staan alle functies en klassen die in het project voorkomen en wat deze doen, alsook hun eventuele parameters en de uitkomst.

- De tool moet in staat zijn om de relaties tussen de verschillende bestanden van een project te visualiseren.

De tool visualiseert de relaties tussen de verschillende bestanden van een project. Deze relaties helpen met het begrijpen van de structuur van het project.

Could Have:

- De tool moet in staat zijn om de documentatie van een Python-bestand te genereren in verschillende formaten.

De tool genereert de documentatie van een Python-bestand in verschillende formaten. Zo kan de gebruiker kiezen in welk formaat de documentatie gegenereerd moet worden.

- De tool moet in staat zijn om de relaties tussen de verschillende functies en klassen van een bestand te visualiseren op project niveau.

De tool visualiseert de relaties tussen de verschillende functies en klassen van een bestand op project niveau. Zo is er geweten welke functies en klassen gebruikt worden door de bestanden.

Nice to Have:

- De tool moet in staat zijn om de documentatie van een Python-bestand te genereren in verschillende talen.

Zo kan de gebruiker kiezen in welke taal het bestand wordt gedocumenteerd.

3.1.2. Niet-functionele requirements

Should Have:

- De tool moet betaalbaar zijn.

Dit wil zeggen dat de tool geen hoge kosten met zich meebrengt.

- De tool moet leesbare documentatie genereren.

De documentatie die de tool genereert moet leesbaar zijn. Dit wil zeggen dat de documentatie duidelijk moet zijn en dat de gebruiker er gemakkelijk informatie uit kan halen.

Nice to Have:

- De tool moet gebruiksvriendelijk zijn.

Dit betekent dat de tool intuïtief moet zijn.

- De tool moet snel werken.

Dit betekent dat de tool in een kleinere tijdspanne documentatie moet genereren dan dat een persoon dit kan.

Requirement	Should have	Could have	Nice to have	Functioneel	Niet Functioneel
Docstrings genereren voor functies en klassen	X			X	
Samenvatting van een Python-bestand genereren	X			X	
Samenvatting van een Python-project genereren	X			X	
Relaties tussen verschillende bestanden visualiseren	X			X	
Documentatie genereren in verschillende formaten		X		X	
Relaties tussen verschillende functies en klassen visualiseren op project niveau		X		X	
Documentatie genereren in verschillende talen			X	X	
Betaalbaar	X				X
Leesbare documentatie genereren	X				X
Gebruiksvriendelijk			X		X
Snel werken			X		X

Tabel 3.1: Requirementsanalyse

3.2. Opstellen van een short-list van bestaande tools

De short-list bestaat uit verschillende tools die gebruikt kunnen worden voor het genereren van documentatie voor Python-projecten. Deze tools worden onderzocht om te kijken welke het beste past bij de requirements van de tool die ontwikkeld wordt in dit onderzoek.

De oplijsting van de tools is gebaseerd op de literatuurstudie en bestaat uit de twee volgende tools:

- GPT4Docstrings (Pedrido, [2023](#))
Een tool die docstrings genereert voor Python-projecten met behulp van GPT4 OpenAI ([2023](#)).
- Doxygen (Doxygen, [2023](#))
Een tool die gebruikt wordt voor het genereren van documentatie voor projecten met reeds een docstring.

Deze tools worden verder onderzocht in de volgende hoofdstukken, GPT4Docstrings in het hoofdstuk [4.1.3](#) en Doxygen in het hoofdstuk [4.2.3](#).

4

Resultaten

4.1. Bestand documentatie

4.1.1. Inleiding

In dit hoofdstuk wordt er gekeken naar de documentatie van een Python-bestand. Eerst wordt de code van het bestand geanalyseerd en worden de verschillende functies en klassen geïdentificeerd. Op basis van deze functies en klassen worden er docstrings gegenereerd, die opnieuw toegevoegd worden aan de code van het bestand. Daarna worden de docstrings binnen het bestand gebruikt om een samenvatting van het bestand te genereren.

Deze samenvatting kan dan als basis gebruikt worden voor het genereren van documentatie voor een Python-project, wat bestaat uit een gehele samenvatting en de relaties tussen de verschillende bestanden van het project. Dit wordt verder onderzocht in het volgende hoofdstuk. Vooraleer dit kan gebeuren, moet de bestand documentatie op punt staan en geoptimaliseerd worden.

Omdat dit onderzoek een bepaalde scope heeft, is er gekozen om enkel te kijken naar het documenteren van correcte Python-bestanden. Dit wil zeggen dat er verwacht wordt dat de code correct is en dat er geen syntax fouten in de code zitten. Er wordt niet gekeken naar het documenteren van bestanden met syntax fouten of bestanden die niet correct zijn.

4.1.2. Keuze van model

Uit de literatuurstudie is gebleken dat GPT3.5-Turbo van OpenAi ([2024a](#)) het beste model is. Dit model heeft de beste prijs-kwaliteit verhouding volgens de tabellen [2.4](#) en [2.3](#) van de literatuurstudie. Dit is een krachtig model dat getraind is op een grote hoeveelheid data en die in staat is om natuurlijke taal te genereren. Aangezien dit model getraind is op een grote hoeveelheid data is het geschikt om met de juiste prompts de gewenste uitkomst te genereren.

```
1 import asyncio
2 async def async_example():
3     """
4     An asynchronous example function.
5
6     This function asynchronously sleeps for 2 seconds.
7
8     Returns
9     -----
10    None
11
12    This function does not return any value.
13    """
14    await asyncio.sleep(2)
```

Codefragment 4.1: Voorbeeld uitkomst van GPT4Docstrings. (Pedrido, [2023](#))

4.1.3. GPT4Docstrings tool

Uit de short-list met bestaande tools die voldoen aan de requirements is gebleken dat de tool GPT4Docstrings van Pedrido ([2023](#)) een tool is die het toelaat om docstrings te genereren voor ongedocumenteerde Python-projecten. Deze tool maakt gebruik van GPT4 (OpenAI, [2023](#)) om de docstrings te genereren. De resultaten van deze tool zijn beoordeeld en geëvalueerd volgens de requirementsanalyse. Een voorbeeld van deze uitkomst is te zien in het codefragment [4.1](#).

Deze tool is enkel in staat om docstrings te genereren voor functies en klassen. In deze bachelorproef wordt GPT3.5-Turbo van OpenAi ([2024a](#)) gebruikt via Azure van Microsoft ([2024](#)). Door het gebruiken van Azure kan de eigen uitgewerkte tool niet vergeleken worden met GPT4Docstrings van Pedrido ([2023](#)) omdat deze een `API_Key` van OpenAi (OpenAi, [2024a](#)) vereist. Hierdoor is er gekozen om de technieken, die GPT4Docstrings gebruikt, te implementeren in een eigen tool. Dit laat toe om de tool uit te breiden en te verbeteren volgens de requirementsanalyse, ook geeft het meer controle over de gegenereerde docstrings.

4.1.4. Abstract Syntax Tree

Voor er docstrings gegenereerd kunnen worden, moet er eerst nagegaan worden hoe de code van een Python-bestand geanalyseerd kan worden. Uit de literatuurstudie is gebleken dat de verschillende functies en klassen in een bestand geïdentificeerd en geëxtraheerd kunnen worden aan de hand van een Abstract Syntax Tree (AST). Het analyseren van de code van de tool GPT4Docstrings gemaakt door Pedrido ([2023](#)) heeft een beter beeld gegeven hoe een AST eruitziet en hoe deze gegenereerd kan worden.

```
1 def get_functions(self):
2     functions = {}
3     for node in ast.walk(self.tree):
4         if isinstance(node, ast.FunctionDef) or isinstance(node,
5             ast.AsyncFunctionDef):
6             function_code = ast.unparse(node)
7             functions[node.name] = function_code
8     return functions
```

Codefragment 4.2: Voorbeeld van het ophalen van functies uit een AST.

Een AST is een boomstructuur die de syntactische structuur van een programma weergeeft. Per knoop in de boom wordt er een deel van de code voorgesteld. Deze knoop kan dan weer kinderen hebben die deel uitmaken van de code. Elke knoop in de boom heeft een type en een waarde.

Het inlezen van een Python-bestand en deze omzetten naar een AST maakt het mogelijk om de code van het bestand te manipuleren. Zo kunnen de verschillende import statements, functies en klassen geïdentificeerd worden.

In 4.2 wordt er met behulp van de `ast.walk` functie door de AST gelopen. Elke node in de AST wordt gecontroleerd of het een functie of een asynchrone functie is. Als dit het geval is, wordt de code van de functie opgehaald en toegevoegd aan een dictionary.

4.1.5. Docstrings

Binnen deze bachelorproef wordt de docstring stijl van Google gehanteerd (Google Python Team, 2024). Deze docstrings bestaan uit een korte beschrijving van de functie of klasse, de argumenten die de functie verwacht en de return waarde van de functie. Een voorbeeld van een docstring voor een functie die controleert of een getal een priemgetal is, kan gevonden worden in het codefragment 4.3.

Deze docstrings dienen gegenereerd te worden voor elke functie en klasse in een Python-bestand op basis van de huidige code van de functie of klasse.

4.1.6. Prompting

Door aan prompt-engineering te doen, kan het model beter aangestuurd worden en kan de gewenste uitkomst volgens de requirementsanalyse bekomen worden. Er werden verschillende prompts getest om het beste resultaat te bekomen. Er zijn prompts gemaakt voor het genereren van docstrings voor functies en klassen.

Prompt engineering voor functies

Het eerste prompt voor het genereren van een docstring voor een functie is te zien

```
1 def is_prime(n: int) -> bool:
2     """
3     Check if a number is prime.
4
5     Args:
6         n (int): The number to check.
7
8     Returns:
9         bool: True if the number is prime, False otherwise.
10    """
```

Codefragment 4.3: Voorbeeld van een docstring voor een functie die controleert of een getal een priemgetal is.

in het codefragment 4.4. Er wordt gevraagd om een docstring te genereren voor een functie. Deze versie van de prompt bevat een voorbeeld van een functie met de verwachte uitkomst.

De volgende versie van dit prompt bevat duidelijkere instructies te vinden in de bijlage B.1.2. Het is belangrijk dat de prompt duidelijk is en dat het model weet wat er verwacht wordt. Daarom staat er in de instructies exact wat er verwacht wordt van het model namelijk dat de gegenereerde functie een docstring moet bevatten en type hints. De code van de functie mag niet aangepast worden en er mogen geen imports toegevoegd worden. Ook mag het model niets veronderstellen over de functie of de data types die gebruikt worden in de functie.

Door het vergelijken van de uitkomst, te zien in het codefragment 4.5, met een vooropgestelde uitkomst B.3.2, een zelfgedocumenteerd bestand, kan er gekeken worden of de gegenereerde docstrings correct was. Er wordt geconstateerd dat de uitkomst van het model correct is met uitzondering van de type hints. Dit probleem is opgelost door met de volgende versie B.1.3 van de prompt de import statements mee te geven. Zo kan het model geen foute veronderstellingen maken, ook al werd er in de instructies duidelijk meegegeven dat dit niet de bedoeling was.

Deze veronderstellingen kwamen er omdat het model de code van de functie sporadisch aanpaste. In het aangepaste prompt werd er duidelijk gemaakt dat de uitkomst van de prompt slechts de functienaam met type hint en de docstring moest bevatten. De code van de functie moest niet meer in de uitkomst staan.

Prompt engineering voor klassen

Het prompt engineering proces voor klassen liep gelijkaardig met dat van functies. Er werd een prompt gemaakt met duidelijke instructies en een voorbeeld van een klasse met de verwachte uitkomst. De instructies waren gelijkaardig aan die van de functies, maar dan voor klassen.

```

1  '''For this Python function:
2  ```python^^I
3  def is_prime(n):
4  if n in [2, 3]:
5      return True
6  if (n == 1) or (n % 2 == 0):
7      return False
8  r = 3
9  while r * r ≤ n:
10     if n % r == 0:
11         return False
12     r += 2
13 return True
14 ```
15 Leave out any imports, just return the function with the docstring
    and type hints.
16 The function, with docstring using the google docstring style and
    with type hints is:
17 ```python^^I
18 def is_prime(n: int) -> bool:
19     """
20     Check if a number is prime.
21     Args:
22         n (int): The number to check.
23     Returns:
24         bool: True if the number is prime, False otherwise.
25     """
26     if n in [2, 3]:
27         return True
28     if (n == 1) or (n % 2 == 0):
29         return False
30     r = 3
31     while r * r ≤ n:
32         if n % r == 0:
33             return False
34         r += 2
35     return True
36 ```
37
38 For this Python function:
39 ```python^^I
40 {code}
41 '''

```

```
1 def crop_faces(plot_images: bool=False, max_images_to_plot: int=5)
   -> List[ndarray]:
2     """
3     Crop faces from images and save them in a directory.
4
5     Args:
6         plot_images (bool, optional): Whether to plot the images.
           Defaults to False.
7         max_images_to_plot (int, optional): Maximum number of images to
           plot. Defaults to 5.
8
9     Returns:
10         List[ndarray]: List of cropped images.
11     """
```

Codefragment 4.5: Uitkomst prompt voor het genereren van een docstring voor een functie v2.

De verschillende prompt versies 1-4 voor klassen zijn identiek aan die van functies, maar dan met de code van een klasse in plaats van een functie. Omdat een klasse bestaat uit verschillende functies en attributen is het belangrijk dat de docstrings van de functies en attributen correct gegenereerd worden. Deze docstrings worden dan meegegeven in de prompt voor het genereren van de docstring van de klasse. Hiervoor is de overige code van de klasse niet nodig, wat dan ook niet meegegeven wordt in de prompt. Ook worden opnieuw de verschillende imports meegegeven aan de prompt omdat dit hallucinaties vermijdt zoals gezien in hoofdstuk 4.1.6. Door de uitkomst, te zien in het codefragment 4.6, van prompt versie 4 B.1.4 te vergelijken met een vooropgestelde uitkomst B.3.3 kon er gekeken worden of de gegenereerde docstrings correct waren. De conclusie hieruit is dat de uitkomst overeenkomt met de vooropgestelde uitkomst.

Prompt engineering voor samenvatting

Voor het genereren van een samenvatting van een Python-bestand werd er een prompt gemaakt met de gegenereerde docstrings van de functies en klassen. De verschillende docstrings werden meegegeven aan de parameter `code_content` en de naam van het bestand aan de parameter `filename`. Het volledige prompt met alle beschrijvingen kan gevonden worden in B.1.5. Door de gekende technieken van prompt engineering gezien in hoofdstuk 2.3.4 te gebruiken kan het model aangestuurd worden. Er wordt meegegeven wat er verwacht wordt van het model, wat er in de uitkomst moet staan en op basis van welke data de uitkomst gegenereerd moet worden.

```

1 class CsvReader:
2     """
3     A class representing a CSV file reader with a method to read the
4       file and return its content as a list of rows.
5
6     Methods:
7         readCsv: Read a CSV file and return its content as a list of rows.
8     """

```

Codefragment 4.6: Uitkomst prompt voor het genereren van een docstring voor een klasse v4.

4.1.7. Toevoegen van gegenereerde docstrings

De gegenereerde docstrings worden vervolgens toegevoegd aan de code van de functies en klassen. Dit gebeurt door de code van de functie of klasse te vervangen door de gegenereerde docstring. Deze kunnen vastgelegd worden in de AST om dan de AST te gebruiken als de nieuwe code van het bestand.

Omdat de uitkomst van de prompts altijd in de vorm van een string met een omsloten code blok wordt gegeven, zoals te zien in het codefragment 4.4, dient dit verwijderd te worden voor het toegevoegd wordt aan de code van het bestand. Dit wordt gedaan door de uitkomst van het model te parsen en de code blokken te verwijderen. Enkel de gegenereerde docstring samen met de functie of klasse declaratie moet behouden worden.

De eerste versie van de code voor het toevoegen van de docstrings aan de code van de functies en klassen is te zien in het codefragment 4.7. Door te testen en te evalueren met verschillende Python-bestanden met moeilijkheidsgraden zoals te zien in 4.1 werd er gekeken of de code correct werkte.

Bestand	Graad	Motivatie
Een python functie met één functie: B.4.1	makkelijk	Eén functie
Een Python-bestand met verschillende functies: B.4.2	gemiddeld	Meerdere functies
Een Python-bestand met functies en klassen: B.4.3	moeilijk	Functies en klassen
Een complex Python-bestand met verschillende functies en klassen en nested functies: B.4.4	extreem	Nested functies en klassen

Tabel 4.1: Aantal functies en klassen in de verschillende Python-bestanden.

In deze versie wordt er door de AST gelopen en wordt er gekeken of de node een functie of klasse is met de juiste naam. Als dit het geval is, wordt de code van de functie of klasse vervangen door de gegenereerde docstring. Het toevoegen van de docstring wordt gedaan door de nieuwe code van de functie of klasse in de AST te plaatsen op de plaats van de oude code en dan de nieuwe AST te gebruiken als de nieuwe code van het bestand.

Deze code werkte niet volledig zoals verwacht. De oude code werd niet verwijderd

```
1 def replace_functions(self, functions):
2     tree = self.tree
3     for node in ast.walk(tree):
4         if isinstance(node, (ast.FunctionDef, ast.AsyncFunctionDef))
5             and node.name in functions:
6             new_func_def = ast.parse(functions[node.name]).body
7             tree.body.insert(tree.body.index(node), new_func_def)
8     self.tree = tree
```

Codefragment 4.7: Vervangen van de code van een functie door de gegenereerde docstring. [B.2.1](#)

uit de AST zoals te zien in het codefragment [4.8](#). Dit zorgde voor dubbele functies en klassen in de AST waarvan één met docstring en één zonder. Dit werd opgelost door de oude code te verwijderen uit de AST [B.2.2](#). Alsook werd de code aangepast zodat functies die binnen een klasse gedefinieerd zijn ook vervangen kunnen worden. Het verwijderen uit de lijst met functies werd ook toegevoegd zodat de functies die al vervangen zijn niet opnieuw vervangen worden.

Deze versie werkte zoals verwacht voor bestanden met moeilijkheidsgraad makkelijk tot moeilijk, bestanden zonder ingewikkelde structuren zoals nested functies of nested klassen. De code liep echter vast bij bestanden met een extreme moeilijkheidsgraad. Hierdoor moest de code opnieuw aangepast worden omdat de gegenereerde docstrings niet altijd correct toegevoegd werden. Een nadeel van het werken met AST is dat de parent node van nested functies niet opgeslagen worden. Dit werd opgelost door het vervangen recursief te laten gebeuren, een betere oplossing dan het gebruiken van if else statements het codefragment [4.9](#).

Door de code recursief te laten lopen, kan de code van nested functies en klassen ook vervangen worden. Door het gebruiken van de parent node van de node die vervangen dient te worden, kan de docstring op de juiste index geplaatst worden. De nieuwe node wordt toegevoegd aan de parent node en de oude node wordt verwijderd. Zo kunnen grote Python-bestanden met complexe structuren ook correct vervangen worden.

4.1.8. Bestand samenvatting genereren

De laatste stap in het proces van het documenteren van een Python-bestand is het genereren van een samenvatting van het bestand. Deze samenvatting wordt gemaakt op basis van de reeds gegenereerde docstrings van de verschillende functies en klassen van het bestand. Het gebruiken van een prompt waar alle docstrings meegegeven worden kan een correcte samenvatting als eindresultaat bekomen. Hierin hoort er een korte beschrijving van het bestand te staan en een lijst

```

1 def crop_image(img, x1, y1, x2, y2):
2
3     def crop_image(img: ndarray, x1: int, y1: int, x2: int, y2: int)
4         -> ndarray:
5             """
6             Crop the input image to the specified dimensions.
7
8             Args:
9                 img (ndarray): The input image.
10                x1 (int): The starting x-coordinate for cropping.
11                y1 (int): The starting y-coordinate for cropping.
12                x2 (int): The ending x-coordinate for cropping.
13                y2 (int): The ending y-coordinate for cropping.
14
15            Returns:
16                ndarray: The cropped image.
17            """
18            if x1 < 0 or y1 < 0 or x2 > img.shape[1] or (y2 >
19                img.shape[0]):
20                img, x1, x2, y1, y2 = pad_img_to_fit_bbox(img, x1, x2,
21                    y1, y2)
22            return img[y1:y2, x1:x2, :]

```

Codefragment 4.8: Stuk uit uitkomst van het vervangen van de code van een functie [B.5.1](#).

```

1 def _replace_functions(self, node, functions):
2     if isinstance(node, (ast.FunctionDef, ast.AsyncFunctionDef)) and
3         node.name in functions:
4         new_func_def = ast.parse(functions[node.name]).body[0]
5         new_func_def.body.extend(node.body)
6         parent_node = self._get_parent_node(node)
7         index = parent_node.body.index(node)
8         parent_node.body.remove(node)
9         parent_node.body.insert(index, new_func_def)
10        functions.pop(node.name)
11    for child_node in ast.iter_child_nodes(node):
12        self._replace_functions(child_node, functions)

```

Codefragment 4.9: Vervangen van de code van een functie door de gegenereerde docstring. [B.2.3](#)

van de functies en klassen die in het bestand voorkomen. Er komt een beschrijving in de samenvatting van de functies en klassen die in het bestand voorkomen. Deze beschrijvingen worden gegenereerd door het model op basis van de gegenereerde docstrings.

Deze samenvatting wordt gegenereerd door het model de gegenereerde docstrings van de functies en klassen mee te geven in een prompt, zoals de prompt [B.1.5](#). Dit is de laatste stap in het proces van het documenteren van een Python-bestand.

Deze samenvatting kan dan gebruikt worden als basis voor het genereren van de verdere documentatie voor een Python-project, een samenvatting op project niveau en de relaties tussen de verschillende bestanden van het project.

4.2. Project documentatie

4.2.1. Inleiding

In dit hoofdstuk wordt er gekeken hoe de individuele samenvattingen van een Python-bestand gebruikt kunnen worden om een samenvatting van het gehele project te maken. Verder wordt onderzocht hoe de relaties tussen de verschillende bestanden gevisualiseerd kunnen worden met als doel een zo goed mogelijk overzicht van het project te krijgen zonder handmatige documentatie.

4.2.2. Projectsamenvatting


De samenvatting van een Python-project kan gemaakt worden door de individuele samenvattingen van de bestanden samen te voegen. Deze samenvatting kan bekomen worden door elk Python-bestand in het project te laten documenteren en de samenvatting ervan op te slaan. Daarna kunnen deze samenvattingen samengevoegd worden om dan mee te geven aan een Large Language Model.

Deze samenvattingen worden gegenereerd door het aanroepen van de functie `generate_file_summaries()`. Deze functie maakt gebruik van de klasse `FileDocumentationGenerator()` die de samenvattingen van de bestanden genereert en opslaat in een dictionary. De code van deze functie is te vinden in [B.2.5](#).

Door een duidelijk prompt mee te geven aan het model kan er specifiek gevraagd worden welke functies en klassen er in het project zitten en dat duidelijk per bestand opgelijst. Samen met deze oplijsting wordt er ook een korte samenvatting van het gehele project weergegeven. Een voorbeeld van de uitkomst is te zien in [4.1](#). Hier is te zien dat er een duidelijk overzicht is van welke functies en klassen er in het project zitten, alsook wat het gehele project inhoudt.

Keuze van welke bestanden te documenteren

Het is belangrijk om te kijken welke bestanden er gedocumenteerd moeten worden. Omdat het gaat over een Python-project, is het belangrijk dat alle Python-bestanden gedocumenteerd worden. Er is de keuze gemaakt om het bestand `__init__.py` niet te documenteren, omdat dit bestand vaak niet relevant is voor




Figuur 4.1: Voorbeeld van een project samenvatting

de documentatie van het project. Het bestand `__init__.py` is vaak leeg of het heeft slechts een minimale functionaliteit.

Documentatie van bestanden zonder functies of klassen

Omdat er eerst vanuit gegaan wordt dat elk bestand functies of klassen bevat, is het belangrijk om te kijken naar bestanden die dit niet bevatten. Deze bestanden dienen ook gedocumenteerd te worden om een volledig overzicht te krijgen van het project. Als er geen apart prompt voorzien wordt, dan zal het model hallucineren en een samenvatting verzinnen. Dit is niet de bedoeling. Er is gebruik gemaakt van een prompt B.1.6 die vraagt om de werking van het document uit te leggen en de eventuele imports die het bestand bevat. In dit prompt wordt er duidelijk gedefinieerd wat er in de documentatie moet staan. Aan de hand van een voorbeeld wordt er getoond hoe de documentatie eruit moet zien. Een voorbeeld van de uitkomst in de project documentatie van een bestand zonder functies is te zien in de figuur 4.2.



Figuur 4.2: Voorbeeld van de documentatie van een bestand zonder functies of klassen

Prompting voor projectsamenvatting

Aangezien de samenvatting van een project bestaat uit de samenvattingen van individuele Python-bestanden, is het belangrijk dat deze op een correcte manier gegenereerd worden. Dit wordt gerealiseerd met behulp van een prompt die de samenvatting van een Python-bestand op een correcte manier interpreteert en omzet naar de juiste documentatie.

De gehele samenvatting van het project werd gemaakt door de individuele samenvattingen van de bestanden samen te voegen en dit mee te geven met het prompt [B.1.7](#). De volgorde van de samenvattingen is niet van belang, omdat de relaties tussen de bestanden later nog gevisualiseerd worden in hoofdstuk [4.2.3](#) en dit op basis van de imports. Dit prompt vraagt om de samenvatting van het project te maken en uit de individuele samenvattingen de functies en klassen op te lijsten.

Doordat het model beter kleine prompts kan verwerken, is er gekozen om de samenvattingen van de bestanden in kleinere stukken mee te geven aan het model. Dit prompt maakt per samenvatting van een Python-bestand de documentatie van de verschillende functies en klassen. De functies en klassen worden opgelijst met het juiste formaat en een kleine uitleg. Deze resultaten van de verschillende kleine prompts werden dan code matig samengevoegd tot een geheel. Door het code matig toevoegen van de individuele samenvattingen gaat er niets verloren. Deze keuze is verkozen omdat de LLM de uitkomst dan correct formateert in markdown. De uitkomst van de samenvatting van het project is te zien in de figuur [4.1](#). Het prompt dat gebruikt werd, is te zien in [B.1.8](#). Dit prompt vraagt om de functies en klassen van een Python-bestand op te lijsten en een korte uitleg te geven wat deze functies en klassen doen. De uitkomst is weergegeven met een duidelijk voorbeeld binnen het prompt en volgens een markdown formaat. De documentatie gegenereerd door dit prompt is te zien in [4.1](#).

4.2.3. Visualisatie van relaties tussen bestanden

Om een goed overzicht te krijgen van het project is het belangrijk om de relaties tussen de verschillende bestanden te visualiseren. Dit kan gedaan worden door gebruik te maken van graven om de relaties tussen de bestanden weer te geven. Omdat er uit de shortlist is gebleken dat er een bestaande tool is die dit kan, namelijk Doxygen ([2023](#)), is deze tool grondig bekeken. Doxygen ([2023](#)) kan pas een visualisatie maken van de relaties tussen de bestanden als deze bestanden uitgebreid gedocumenteerd zijn. De relaties tussen de bestanden moeten expliciet in de documentatie vermeld zijn. Doordat deze tool documentatie vergt, is er gekeken hoe deze relaties gegenereerd kunnen worden met behulp van LLM's. Ook is er gekeken hoe Doxygen deze relaties visualiseert. Er wordt gebruik gemaakt van Graphviz van The Graphviz Authors ([2024](#)).

Graphviz (The Graphviz Authors, [2024](#)) kan echter niet gebruikt worden in een Python omgeving, de taal waarin dit onderzoek geschreven is. Daarom is er gekeken

naar een alternatief en soortgelijke tool om de relaties te tonen. De tool Pyvis van West Health Institute Revision (2018) is een Python library die te gebruiken is om graven te maken en te visualiseren. Dit laat het toe om de relaties tussen de verschillende bestanden te visualiseren en een duidelijk overzicht te krijgen van het project.

Genereren van de relaties tussen bestanden in een project

Om de relaties te bekomen tussen alle bestanden en mappen in een project is er een prompt meegegeven aan het Large Language Model. In dit prompt worden de imports van alle bestanden opgelijst en wordt er gevraagd om de relaties tussen de bestanden weer te geven op basis van de prompts. Een bestand dat een functie uit een ander bestand gebruikt, importeert deze functie impliciet. Daardoor wordt de functie die gebruikt wordt ook opgesomd onder de imports van het bestand. Hierdoor kan er gekeken worden naar de imports van de verschillende bestanden en zo kunnen de relaties tussen de bestanden worden gevisualiseerd.

Het prompt dat gebruikt werd, is te zien in het codefragment 4.10.

Er zijn verschillende iteraties van dit prompt gemaakt om de beste resultaten te bekomen. Deze iteraties en fouten in het prompt hebben enige tijd in beslag genomen om op te lossen, maar uiteindelijk zijn de kinderziektes opgelost. Zo is het belangrijk dat er geen spaties in het voorbeeld CSV staan. De uitkomst van dit prompt is een CSV bestand met daarin het pad van het bestand, de bestandsnaam, het pad van de folder waarin het bestand zit en een lijst van alle geïmporteerde bestanden. Omdat dit CSV bestand de basis is voor de graaf die later gemaakt wordt, is het belangrijk dat dit bestand correct gegenereerd wordt. Ook zijn schrijffouten en onduidelijkheden in het prompt aangepast om een beter resultaat te bekomen. Een verdere iteratie van het prompt laat het toe om alle imports in het CSV te laten staan. Er wordt achteraf gefilterd op de imports die niet relevant zijn. Wanneer er meerdere imports zijn, wordt er gevraagd aan de prompt om deze op te slaan in een lijst gescheiden door een puntkomma.

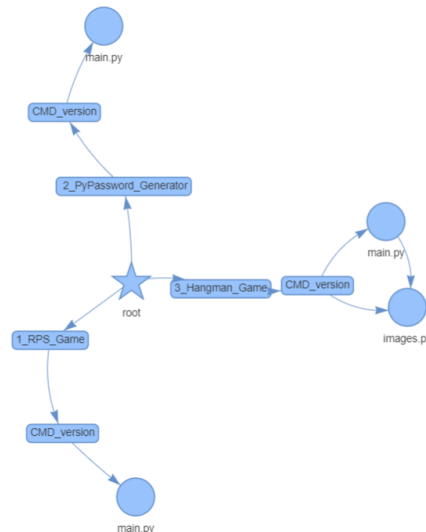
Visualisatie van de relaties

Eens er een goed CSV bestand is bekomen, kunnen de relaties tussen de bestanden gevisualiseerd worden. Dit wordt gedaan met behulp van de tool Pyvis (West Health Institute Revision, 2018). Deze tool haalt de relaties uit het CSV bestand en voegt deze toe aan een graaf. Eerst worden de verschillende nodes toegevoegd en dan de edges tussen de nodes waar er een relatie is. De code waarop dit gebeurt is te vinden in bijlage B.2.6. Als dit voor alle bestanden gedaan is, kan er een duidelijk overzicht bekomen worden van de relaties tussen de bestanden door de graaf te exporteren naar een HTML bestand. Dit HTML bestand kan dan geopend worden in een browser om de graaf te bekijken, alsook kunnen de nodes versleept worden om een beter overzicht te bekomen.

Er is een voorbeeld van een graaf te zien in de figuur 4.3. Voor een groot project is

```
1 '''
2     You are an AI documentation assistant, and your task is to
3       generate a csv file containing the relations between the
4       files in a Python project.
5
6     For the given project structure and imports:
7     The imports are as follows:
8     ...
9
10    The structure of the project is as follows:
11    ...
12
13    The expected output of your task is the following:
14    ```csv
15    File_Path,File_Name,Folder_Path,Uses_File
16    ...
17    ```
18
19    The Column "Uses File" should only contain the files where the
20    file imports functions from.
21    For example if the imports are:
22    ```python
23    ...
24    from images import open_image
25    from stages import stage1
26    ```
27
28    The Column "Uses File" should contain the file
29    '4_Hangman_Game\\CMD_version\\images.py' and
30    '4_Hangman_Game\\CMD_version\\stages.py'
31
32    Do your task given the following imports and structure of the
33    project:
34
35    The imports are as follows:
36    {imports}
37
38    And the structure of the project is as follows:
39    {structure}
40
41    THE OUTPUT SHOULD BE A SINGLE CSV FILE CONTAINING THE RELATIONS
42    BETWEEN THE FILES IN THE PROJECT.
43    '''
```

Codefragment 4.10: Prompt voor het genereren van de relaties tussen de bestanden in een project, vervoledigd in bijlage [B.2.4](#)



Figuur 4.3: Voorbeeld van een graaf van de relaties tussen bestanden

er geprobeerd of de gegenereerde graaf de relaties tussen de bestanden duidelijk kan weergegeven op een grotere schaal, een voorbeeld hiervan is te vinden in de figuur 4.4. De relaties op deze graaf zijn zichtbaar, echter is het niet altijd duidelijk omdat er veel bestanden zijn en er bepaalde bestanden vaak geïmporteerd zijn. Dit kan ervoor zorgen dat de graaf onoverzichtelijk wordt naargelang de grootte van het project.

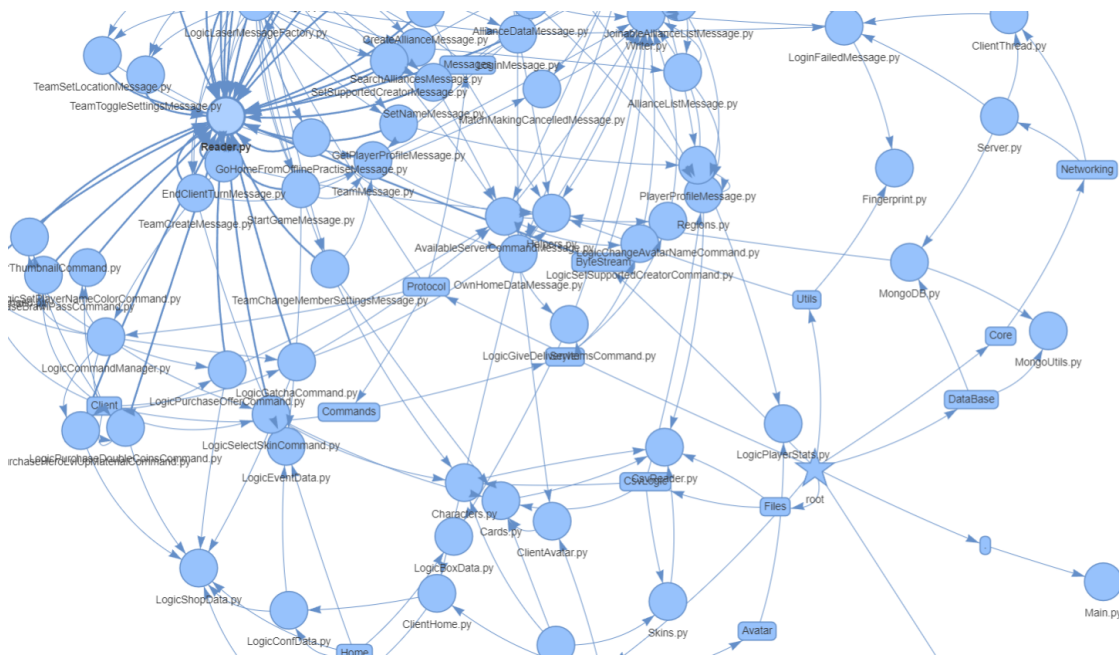
4.3. Evaluatie

4.3.1. Inleiding

In dit hoofdstuk wordt er gekeken hoe de documentatie van een project geëvalueerd kan worden. Dit wordt gedaan door de documentatie van de tool te vergelijken met de handgeschreven documentatie van een project. Het bestand dat vergeleken wordt, is het Python-bestand met de naam AutoClicker van de Waegeneer (2022) en het Python-project met de naam bmi-project van Simmons (2019).

4.3.2. Bestandsdocumentatie evaluatie

Door het testen van de moeilijkheidsgraden opgesteld in de tabel 4.1 kon de tool geëvalueerd worden. De tool werkte zoals verwacht voor bestanden met moeilijkheidsgraad makkelijk tot moeilijk. Het vergelijken van de zelfgedocumenteerde bestanden met de automatisch gegenereerde bestanden geeft een goed beeld van de kwaliteit van de gegenereerde docstrings en bestandsamenvattingen wat te zien is in de figuur 4.5. Hieruit is te zien dat de functie omschrijvingen in de samenvatting anders verwoord zijn, maar de betekenis is hetzelfde. Er is echter één functie vergeten in de manuele bestandsamenvatting, die wel gedocumenteerd is door de tool. Een tweede fout in de automatisch gegenereerde bestandsamen-



Figuur 4.4: Voorbeeld van een fragment van een graaf van de relaties tussen bestanden van een groot project

Type documentatie	Aantal die niet overeenkomen	Aantal exacte overeenkomsten	Aantal gelijkaardige overeenkomsten	Totale aantal
Docstring	2	5	13	20
Bestandsamenvatting	3	2	3	8

Tabel 4.2: Evaluatie van de documentatie van het project bmi-project van Simmons (2019)

vatting is dat de klasse `MouseClicked` een andere naam heeft gekregen namelijk `AutoClicker` de naam van het bestand. Dit is een goed resultaat, omdat de gegenereerde docstrings correct zijn en het geeft toch een duidelijk beeld van wat het bestand inhoudt.

4.3.3. projectdocumentatie evaluatie

De projectdocumentatie evaluatie bestaat uit het evalueren van de documentatie van een project gegenereerd door de tool en de handgeschreven documentatie van het project. Dit wordt gedaan voor het project genaamd bmi-project van Simmons (2019).

Alle docstrings en bestandsamenvattingen zijn geëvalueerd en de resultaten zijn te zien in de tabel 4.2. 37.5% van de automatisch gegenereerde samenvattingen hebben dezelfde betekenis als de handgeschreven samenvattingen. 25% van de samenvattingen zijn exact hetzelfde. Wanneer de bestandsamenvattingen niet overeenkomen is dit omdat er een klasse of functie extra toegevoegd is in de automatische gegenereerde samenvatting die niet in het origineel bestand staat. Een voorbeeld van deze foutieve bestandsamenvattingen is te zien in de figuur 4.6.

De docstrings komen voor 90% overeen met de handgeschreven docstrings. In 10% van de andere gevallen is er een kleine fout in de docstring of is de docstring niet

```

"""
Summary of file autoClicker.py:

This file contains the implementation of a class to handle mouse clicking functionality.

Classes:
    ClickMouse: Class to handle the mouse clicking functionality

Functions:
    start_clicking: Start the clicking process
    stop_clicking: Stop the clicking process
    exit: Exit the clicking process
    run: Run the clicking process in a loop
    on_press: Function to handle the key press events
"""

```

(a) Zelfgedocumenteerde bestandsamenvatting. [B.3.2](#)

```

"""
Summary of file: autoClicker.py

This file contains the implementation of an AutoClicker class for simulating mouse clicks.

Classes:
    AutoClicker: A class to simulate mouse clicks.

Functions:
    on_press: Simulate mouse click when a specific key is pressed.
    __init__: Initialize the AutoClicker class with default settings.
    start_clicking: Start simulating mouse clicks.
    stop_clicking: Stop simulating mouse clicks.
    exit: Exit the AutoClicker program.
    run: Run the AutoClicker program.
    ClickMouse: Simulate a single mouse click at the specified position.
"""

```

(b) Automatisch gegenereerde bestandsamenvatting van eigen tool. [B.6](#)

Figuur 4.5: Evaluatie van de automatisch gegenereerde bestandsamenvatting met de zelfgedocumenteerde bestandsamenvatting. Voor het bestand AutoClicker van de Waegeneer ([2022](#))

```

"""
Summary of file: train_generator.py

This file contains the implementation of functions to plot images from a generator and to augment an image.

Functions:
    plot_imgs_from_generator: Plot images from a generator.
    augment_image: Augment an image.
"""

```

(a) Zelfgedocumenteerde bestandsamenvatting.

```

"""
Summary of file: train_generator.py

This file contains a class for generating training data and a function for augmenting images.

Classes:
    TrainGenerator: A class for generating training data.

Functions:
    plot_imgs_from_generator: Plot images from a data generator.
    augment_image: Augment an image with various transformations.
"""

```

(b) Automatisch gegenereerde bestandsamenvatting van eigen tool.

Figuur 4.6: Vergelijking van de automatisch gegenereerde bestandsamenvatting met de zelfgedocumenteerde bestandsamenvatting.

```
class MAECallback(Callback):
    """
    Callback to calculate the mean absolute error on the validation set.

    Args:
        Callback: The base class for Keras callbacks.

    Methods:
        on_train_begin(self, logs: dict): Initialize the data.
        on_epoch_end(self, batch: int, logs: dict): Calculate the mean absolute error on the validation set.
        get_data(self): Get the data.
    """
```

(a) Zelfgedocumenteerde docstring.

```
class MAECallback(Callback):
    """
    A class representing a custom callback for Mean Absolute Error with methods to be
    called at the beginning of the training, at the end of each epoch, and to get the data.

    Methods:
        on_train_begin: Called at the beginning of the training.
        on_epoch_end: Perform actions at the end of each epoch.
        get_data: Get the data.
    """
```

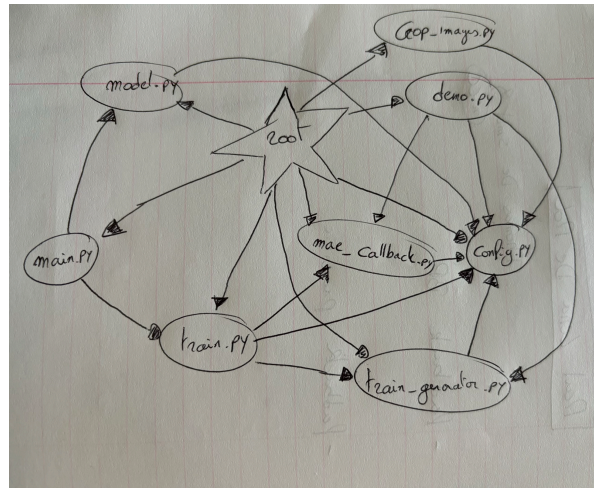
(b) Automatisch gegenereerde docstring van eigen tool.

Figuur 4.7: Vergelijking van de automatisch gegenereerde docstring met de zelfgedocumenteerde docstring.


correct gegenereerd. Dit gaat dan over een verkeerde omschrijving van de functie of klasse of een fout in de parameters. Zo is er voor de docstring van de klasse `MAECallback(Callback)` een fout in de automatisch gegenereerde docstring. Het argument `Callback` is niet meegegeven in de docstring, terwijl dit wel in de handgeschreven docstring staat. Deze fout is te vinden in de figuur 4.7.

De handgeschreven projectsamenvatting heeft dezelfde boodschap als de automatisch gegenereerde samenvatting. Het is echter wel geschreven op een andere manier. Doordat de samenvatting dezelfde boodschap overbrengt, kan er gesproken worden van een duidelijke samenvatting. De olijsting van de verschillende bestanden met elk de gedefinieerde functies en klassen is correct en duidelijk.

De evaluatie van de relaties tussen de verschillende bestanden gebeurt tussen de automatisch gegenereerde graaf en de manueel getekende graaf. De graven, te zien in 4.8, tonen de relaties tussen de bestanden van het project. Het is duidelijk dat deze graven gelijkaardig zijn. De gegenereerde graaf is beweegbaar en kan aangepast worden om een beter overzicht te krijgen. Samen met de olijsting van de bestanden en de graaf met de relaties tussen de bestanden kan er een duidelijk overzicht bekomen worden van het project.



(a) Handgetekende graaf van de relaties tussen de bestanden van het project (Simmons, 2019)



(b) Gegenerateerde graaf van de relaties tussen de bestanden van het project. (Simmons, 2019)

Figuur 4.8: Vergelijking van de gegenereerde graaf met de handgetekende graaf.

5

Conclusie

Het onderzoek had als doel de vraag te beantwoorden: "Hoe kan geautomatiseerde documentatiegeneratie met behulp van Large Language Modellen (LLM) effectief worden toegepast op ongedocumenteerde Python-projecten om er duidelijke en overzichtelijke documentatie van te maken?" Hiervoor werd er een tool ontwikkeld die voldeed aan de requirements die werden opgesteld in het onderzoek. Enkele van deze requirements zijn dat de tool docstrings kan genereren dat er een bestand en een projectsamenvatting gegenereerd kan worden en dat de tool zo goedkoop mogelijk moet zijn. Voor deze vraag beantwoord kan worden, is het belangrijk om te weten wat er juist bedoeld wordt met documentatie. Onder documentatie wordt er begrepen dat er per bestand docstrings en een samenvatting van het bestand wordt gegenereerd. Voor een project wordt er een samenvatting van het project gegenereerd en een overzicht van alle bestanden in het project in de vorm van een graaf met de relaties.

Ook is het belangrijk om te weten wat enkele bestaande documentatietools zijn. Tools zoals Sphinx, Doxygen en Pdoc zijn in staat om een gedocumenteerd project om te zetten in een website of API. Deze tools zijn echter niet in staat om ongedocumenteerde projecten te documenteren. Vervolgens werd de tool GPT4Docstrings besproken. Deze tool is in staat om docstrings te genereren voor Python-projecten, de code van GPT4Docstrings werd gebruikt in de ontwikkeling van de tool.

Het documenteren van een bestand gebeurt door de code van het bestand in te lezen en per functie of klasse een docstring te genereren. Vervolgens worden deze docstrings samengevoegd tot een bestandssamenvatting. Om een project te documenteren worden de verschillende bestanden in het project gedocumenteerd en worden de bestandssamenvatting samengevoegd tot één projectsamenvatting. Tot slot wordt er een graaf gegenereerd die de relaties tussen de bestanden visualiseert.

Er werd gekozen om een Large Language Model te gebruiken om de documenta-

tie te genereren omdat deze modellen getraind zijn op grote hoeveelheden data om zowel code als natuurlijke taal te kunnen begrijpen en genereren. Door het gebruiken van GPT3.5-Turbo werd de tool zo goedkoop mogelijk gehouden.

Door de automatische gegenereerde documentatie van een project te evalueren met een vooropgesteld manueel gedocumenteerd project werd er gekeken naar de verschillen en overeenkomsten tussen de documentatie van de tool en de handgeschreven documentatie. De resultaten van de evaluatie tonen aan dat de documentatie van de tool en de handgeschreven documentatie gelijkaardig zijn. Alhoewel er enkele fouten in de documentatie van de individuele bestanden zitten, blijft de gehele projectdocumentatie overzichtelijk en duidelijk.

Een verdere evaluatie van de tool kan gebeuren door een grote groep programmeurs verschillende projecten handmatig te laten documenteren en dit te chronometreran. Dezelfde projecten kunnen dan ook automatisch gedocumenteerd worden met de tool. De snelheid van de tool kan dan vergeleken worden met de snelheid van de programmeurs. Daarna kan er een enquête afgenomen worden waarbij de programmeurs de keuze hebben tussen de handmatig gedocumenteerde projecten en de automatisch gedocumenteerde projecten. Deze evaluatie kan dan gebruikt worden om de tool te verbeteren.



Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

A.1. Samenvatting

Documentatie van een Python project is belangrijk, maar het is een tijdrovende taak en het wordt vaak niet grondig gedaan. Deze bachelorproef aan de HoGent onderzoekt het automatisch genereren van documentatie voor python projecten met behulp van Large Language Modellen. Er wordt een tool ontwikkeld die de Python code en de relaties tussen de verschillende bestanden analyseert en op basis daarvan een overzichtelijke documentatie genereert. Er wordt gekeken naar hoe de documentatie van Python functies gebruikt kunnen worden voor het maken van een gehele samenvatting van het project. Dit wordt gedaan op basis van huidige methoden om docstrings aan te maken en te gebruiken. Deze informatie kan dan gegeven worden aan de Large Language Modellen om een samenvatting te genereren.

Er worden verschillende Python projecten verzameld en geanalyseerd om te kijken hoe de documentatie gegenereerd kan worden. Dan worden er LLMs getraind op basis van deze projecten en wordt er gekeken naar hoe de documentatie gegenereerd kan worden. De gegenereerde documentatie kan dan vergeleken worden met de huidige documentatie van de projecten om dit te evalueren. Ook zal er gevraagd worden aan enkele programmeurs om de documentatie te evalueren.

Op basis van deze feedback kan het model gefinetuned worden. Er kan gekeken worden naar de mogelijke verbeteringspunten zodat er uiteindelijk een betere documentatie van het project ontstaat. Het resultaat is dat er een tool is die de documentatie van een Python project kan genereren. Dit resultaat maakt het mogelijk

om de gegenereerde samenvatting van een Python project te lezen. De lezer kan dan stukken gebruiken uit het project of er verder mee aan de slag gaan.

A.2. Introductie

Documentatie is belangrijk wanneer er aanpassingen moeten gebeuren aan de code van een project. Ook moet iemand anders de code kunnen begrijpen zodat dit gebruikt kan worden binnen een ander project. Hoe kan geautomatiseerde documentatiegeneratie met behulp van Large Language Modellen (LLM) effectief worden toegepast om duidelijke en informatieve overzichten te produceren voor Python projecten?

Het is belangrijk dat de skills of de know-how van een project gedeeld kunnen worden met anderen. Door het toepassen van documentatie kan deze kennis gemakkelijk vergaard worden door andere geïnteresseerden. Het is dus belangrijk dat er aan documentatie gedaan wordt en dat deze up-to-date blijft.

Documentatie is iets dat veel tijd kost en waar vaak geen aandacht aan wordt besteed. Het gebruik ervan kan ervoor zorgen dat er geen dubbel werk gedaan moet worden. Een tool die dit proces kan versnellen / automatiseren zou een grote meerwaarde zijn. De tool bestaat uit een geautomatiseerde documentatie LLM die de project code analyseert en samenvat in een document. Dit geeft de werknemers de mogelijkheid om zich in te lezen in het project en erna zelf aanpassingen te maken of stukken code te gebruiken voor een ander project.

Het eindresultaat van deze bachelorproef is een Proof of Concept (PoC) van een geautomatiseerde tool die de project code analyseert en er documentatie van genereert. De gegenereerde documentatie laat het toe het project te begrijpen zonder er te veel tijd aan te besteden.

A.3. Literatuurstudie

Wat is documentatie binnen Python projecten en wat zijn de huidige tools? Voor de taal Python bestaan er al verschillende tools die documentatie genereren voor blokken code zoals pdoc (Gallant & Hils, 2023) en Sphinx (Sphinx Team, 2023). Met behulp van de Sphinx autodoc functie (Sphinx Team, 2023) kan een python functie omschreven worden in een docstring. Een docstring is een blok tekst dat de werking van een python functie omschrijft. Door deze beknopte blok tekst wordt er duidelijk wat de functie doet. Deze docstrings kunnen mogelijk gebruikt worden bij het maken van een document dat het project omschrijft.

Wat zijn Large Language Modellen (LLM)? Large Language Modellen zijn neurale netwerken die getraind worden op grote hoeveelheden tekst. Deze modellen kunnen tekst genereren op basis van een gegeven input. LLMs hebben een grote vooruitgang gekend in 2017 door de paper van Vaswani e.a. (2017). Hieruit kwam een nieuw neurale netwerk, self-attention of transformers. Deze doen het beter dan de

vorige neurale netwerken, Convolutional Neural Networks (CNN) en Recurrent Neural Networks (RNN). Door deze nieuwe neurale netwerken zijn er krachtige LLMs ontstaan zoals: GPT van OpenAi (Radford e.a., 2018) en BERT van Devlin e.a. (2019). Hoe kunnen deze Large Language Modellen gebruikt worden om documentatie te genereren? Er kan een prompt geschreven worden die aan de LLMs gegeven wordt, er kan een nieuw LLM getraind worden op correcte samenvattingen van gehele Python projecten. Het gebruiken van docstrings of uitleg van verschillende Python functies kan gegeven worden aan een LLM. Ook kan er gekeken worden naar GitHub README.md bestanden. Dit zijn bestanden waarin de werking van een project kort wordt uitgelegd. Deze zijn echter niet altijd vlot te lezen. Volgens de studie Gao e.a. (2023) kan de tekst vereenvoudigd worden terwijl steeds de correcte betekenis kan behouden worden en dit aan de hand van een transfer learning model. Doordat het vereenvoudigen van een README bestand mogelijk is, kan dit mogelijk gebruikt worden voor de uiteindelijke documentatie die beoogd wordt in deze bachelorproef. Zo kan een redelijk complexe samenvatting vereenvoudigd worden naar de essentie ervan terwijl het steeds een bepaalde diepgang behoudt. In 2023 werd het gebruiken van LLMs bij het automatisch documenteren van code met behulp van syntax bomen onderzocht door Procko en Collins (2023) voor C# en .NET programmeertalen. Er kan gekeken worden hoe er te werk is gegaan en wat de conclusies waren. Er werd gebruik gemaakt van GPT-3.5 en een dotnet compiler Roslyn ("Roslyn", dotnet", z.d.). Hieruit kan geconcludeerd worden dat door het gebruiken van syntax bomen de stochastische onzekerheid van GPT-3.5 een deel verholpen kan worden.

In de studie van McBurney en McMillan (2014) werd onderzocht hoe er automatisch documentatie gegenereerd kan worden voor Java code. Er werd specifiek gekeken hoe de methodes met elkaar verbonden waren en welke rol deze speelden binnen het project. Deze studie was een vervolg op het onderzoek van Sridhara e.a. (2010) in 2010. Het zoeken naar de mogelijke gelijkenissen tussen de automatische documentatie voor Java code en deze van Python code kan een begin zijn van deze bachelorproef.

Er is ook al onderzoek gedaan naar het automatisch genereren van documentatie van code blokken met behulp van een Neural Attention Model (NAM) (Iyer e.a., 2016). Dit onderzoek heeft gekeken naar het genereren van hoogstaande samenvattingen van source code. Het maakt gebruik van neurale netwerken die stukken C# code en SQL queries omzetten naar zinnen die de code omschrijven. Dit helpt bij het begrijpen van stukken code maar niet van een geheel project waar meerdere bestanden bij betrokken zijn.

De afgelopen jaren is het automatisch documenteren van source code grondig bestudeerd en onderzocht. In deze bachelorproef wordt er verder onderzocht hoe LLMs gebruikt kunnen worden bij het automatisch genereren van documentatie of samenvattingen van een geheel Python project. Het uiteindelijke doel is het au-

tomatisch genereren van een samenhangend geheel van verschillende bestanden van een Python project die samen een duidelijk overzicht geven van de werking van het project. Bij het automatisch genereren van documentatie kan er gebruik gemaakt worden van LLMs en kan er gekeken worden hoe verschillende LLMs presenteren tegenover elkaar.

De uitkomst is een samenvatting van het gehele project dat de lezer in staat stelt het project te gebruiken of aan te passen zonder de totale project code te ontleden.

A.4. Methodologie

Het onderzoek bedraagt zes verschillende fases. De eerste fase bedraagt het verder uitvoeren van de literatuurstudie om zo een betere kennis over het onderwerp te vergaren. Het verfijnen van de literatuurstudie zorgt ervoor dat er specifieke methoden gevonden worden die relevant zijn voor Python projecten. Ook dient de probleemdefinitie aangescherpt te worden door specifieke uitdagingen te identificeren. Hiervoor worden twee weken ingepland.

De volgende twee weken bedraagt het verzamelen van de dataset. Er worden Python projecten verzameld die variëren in complexiteit en grootte. We gaan opzoek naar open source python projecten op github, hiervan nemen we de python files als data en de README files als de gewenste uitkomst / target. Vervolgens wordt de data voorbereid zodat deze gebruikt kan worden door de verschillende gekozen LLMs.

In de derde fase wordt het model gekozen en wordt dit model getraind. Er kunnen verschillende LLMs gekozen worden zoals GPT-3.5, gemini, Code LLama (speciale LLM voor python code) of BERT. Er kan ook overwogen worden om een LLM te finetunen op python documentatie. De volgende stap houdt het opstellen van hoe de prestaties van de modellen vergeleken kunnen worden in. Dit kan pas nadat er een plan is opgesteld voor het trainen op de bekomen dataset. Deze fase bedraagt drie weken.

De vierde fase zal de implementatie en evaluatie bevatten. Er wordt een tool gemaakt waar een Python project aangegeven kan worden. De uitvoer van deze tool is een document met een samenvatting van het python project inclusief relaties tussen de verschillende bestanden. Deze uitvoer moet dan geevalueerd te worden op basis van de relevantie, begrijpelijkheid en de volledigheid. De resultaten kunnen vergeleken worden met de documentatie van bestaande tools. Ook kan er gevraagd worden aan enkele programmeurs de gerealiseerde documentatie te evalueren. De vierde fase neemt vier weken in beslag.

De voorlaatste fase bestaat uit het optimaliseren van het generatieproces en het finetunen van de uitkomst. De finetuning stelt de tool in staat om betere documentatie te genereren op basis van de bekomen feedback. Deze fase duurt één week.

De laatste fase van het onderzoek bestaat uit het analyseren van de kritische feed-

back en het afwerken van de bachelorproef. Het rapport wordt geschreven en de presentatie wordt voorbereid. Er kan nagedacht worden over wat er verder onderzocht kan worden na de bekomen conclusies.

A.5. Verwacht resultaat, conclusie

Het verwachte resultaat van deze bachelorproef is dat er een werkende tool gemaakt wordt dat een geheel Python project kan analyseren en er documentatie van kan genereren. Deze documentatie geeft dan een duidelijk overzicht van de werking van het project en de relaties tussen de verschillende bestanden.

Er kunnen verschillende conclusies getrokken worden uit het onderzoek. LLMs zijn ideale modellen om te gebruiken bij het genereren van documentatie. Het finetunen van een LLM op Python documentatie kan een grote meerwaarde zijn bij het genereren van documentatie. Hierdoor is het mogelijk dat de documentatie specifiek afgestemd is voor de verschillende noden van gebruikers. Iedere gebruiker kan de automatische documentatie aanpassen naar zijn eigen noden.

Een verdere conclusie is dat het gebruiken van de documentatie tool het begrijpen van een Python project makkelijker maakt. De kennis van een project kan gemakkelijk gedeeld worden met anderen en anderen kunnen deze documentatie begrijpen.

B

Bijlage

B.1. Prompts

B.1.1. Function Prompt 1

Instructies voor het genereren van een docstring voor een functie versie 1.

```
1 '''For this Python function:
2 ```python^^I
3 def is_prime(n):
4     if n in [2, 3]:
5         return True
6     if (n == 1) or (n % 2 == 0):
7         return False
8     r = 3
9     while r * r ≤ n:
10         if n % r == 0:
11             return False
12         r += 2
13     return True
14 ```
15 Leave out any imports, just return the function with the docstring
16     and type hints.
17 The function, with docstring using the google docstring style and
18     with type hints is:
19 ```python^^I
20 def is_prime(n: int) -> bool:
21     """
22     Check if a number is prime.
```



```

21 Args:
22     n (int): The number to check.
23 Returns:
24     bool: True if the number is prime, False otherwise.
25 """
26 if n in [2, 3]:
27     return True
28 if (n == 1) or (n % 2 == 0):
29     return False
30 r = 3
31 while r * r ≤ n:
32     if n % r == 0:
33         return False
34     r += 2
35 return True
36 ```
37
38 For this Python function:
39 ```python^^I
40 {code}
41 '''

```

B.1.2. Function Prompt 2

Instructies voor het genereren van een docstring voor een functie versie 2.

```

1 '''
2     The following Python function is a code snippet from a Python
3     file.
4     The following function lacks a docstring and type hints.
5     Your task is to add a docstring and type hints to the function.
6     You can't change the function's code, add any imports, or assume
7     anything about the function's behavior or datatypes that is
8     not clear from the code snippet itself.
9     Below is a function that needs a docstring and type hints:
10    ```python^^I
11    def is_prime(n):
12        if n in [2, 3]:
13            return True
14        if (n == 1) or (n % 2 == 0):
15            return False
16        r = 3

```

```

14     while r * r ≤ n:
15         if n % r == 0:
16             return False
17         r += 2
18     return True
19
20 The correct outcome should be the following Python code:
21 ```python^^I
22 def is_prime(n: int) -> bool:
23     """
24     Check if a number is prime.
25     Args:
26         n (int): The number to check.
27     Returns:
28         bool: True if the number is prime, False otherwise.
29     """
30     if n in [2, 3]:
31         return True
32     if (n == 1) or (n % 2 == 0):
33         return False
34     r = 3
35     while r * r ≤ n:
36         if n % r == 0:
37             return False
38         r += 2
39     return True
40
41
42 Now it's your turn to add a docstring and type hints to the
43 following function:
44 ```python^^I
45 {code}
46 """

```

B.1.3. Function Prompt 3

Prompt versie 3 voor het genereren van een docstring voor een functie.

```
1 '''You are an AI documentation assistant, and your task is to
   generate docstrings and typehints based on the given code of a
   function, the function is a code snippet from a Python file.
2 Do your task with the least amount of assumptions, you can't add any
   imports, change the code, or assume anything about the
   function's behavior or datatypes that is not clear from the code
   snippet itself.
3 The purpose of the documentation is to help developers and beginners
   understand the function and specific usage of the code.
4
5 An example of your task is as follows:
6 The given code is:
7
8 ```python^^I
9 def is_prime(n):
10     if n in [2, 3]:
11         return True
12     if (n == 1) or (n % 2 == 0):
13         return False
14     r = 3
15     while r * r ≤ n:
16         if n % r == 0:
17             return False
18         r += 2
19     return True
20 ```
21
22 The expected output of your task for the given code is:
23
24 ```python^^I
25 def is_prime(n: int) -> bool:
26     """
27     Check if a number is prime.
28
29     Args:
30         n (int): The number to check.
31
32     Returns:
33         bool: True if the number is prime, False otherwise.
34     """
35
```

```

36 if n in [2, 3]:
37     return True
38 if (n == 1) or (n % 2 == 0):
39     return False
40 r = 3
41 while r * r ≤ n:
42     if n % r == 0:
43         return False
44     r += 2
45 return True
46 ```
47
48 Now it's your turn to generate the docstrings and typehints for the
49 following function of a file with these imports:
50 {imports}
51
52 The content of the code is as follows:
53 {code_content}
54 '''

```

B.1.4. Class Prompt 1

Prompt voor het genereren van een docstring voor een klasse.

```

1  '''
2  You are an AI documentation assistant, and your task is to generate
3  docstrings and typehints based on the given code of a class, the
4  class is a code snippet from a Python file.
5
6  Do your task with the least amount of assumptions, you can't add any
7  imports, change the code, or assume anything about the classes
8  behavior or datatypes that is not clear from the code snippet
9  itself.
10 The purpose of the documentation is to help developers and beginners
11 understand the function and specific usage of the code.
12
13 An example of your task is as follows:
14 The given code is:
15
16 ```python
17 class Circle:
18     def __init__(self, radius: float) -> None:
19         """

```

```
13         Initialize the Circle object with a given radius.
14
15     Args:
16         radius (float): The radius of the circle.
17     """
18     self.radius = radius
19
20     def calculate_area(self) -> float:
21         """
22         Calculate the area of the circle.
23
24         Returns:
25             float: The area of the circle.
26         """
27         return round(math.pi * self.radius ** 2, 2)
28
29     def calculate_circumference(self) -> float:
30         """
31         Calculate the circumference of the circle.
32
33         Returns:
34             float: The circumference of the circle.
35         """
36         return round(2 * math.pi * self.radius, 2)
37
38
39 The expected output of your task for the given code is:
40
41 ```python
42 class Circle:
43     """
44     A class representing a circle with methods to calculate its area
45     and circumference.
46
47     Attributes:
48         radius (float): The radius of the circle.
49
50     Methods:
51         __init__: Initialize the Circle object with a given radius.
52         calculate_area: Calculate the area of the circle.
```

```

52         calculate_circumference: Calculate the circumference of the
           circle.
53     """
54     ```
55
56 Now it's your turn to generate the docstrings and typehints for the
   following class of a file with these imports:
57 {imports}
58
59 The content of the code is as follows:
60 {code_content}
61
62 Only generate the class docstring
63
64 '''

```

B.1.5. Samenvatting van een bestand

Prompt voor het genereren van een samenvatting van een bestand.

```

1  '''
2  You are an AI documentation assistant, and your task is to generate
   a summary of the given Python file.
3  The summary should include the following information:
4  - What the file does.
5  - What classes are defined in the file.
6  - What functions are defined in the file.
7  - And a brief description of each class and function.
8  - Include the file name at the beginning of the summary.
9
10 You are going to generate the summary based on given function names,
   class names and their docstrings.
11
12 Now it's your turn to generate the summary given the following code
   of the file: {filename}:
13
14 {code_content}
15 '''

```

B.1.6. Bestand zonder functies of classes

Prompt voor het genereren van een samenvatting van een bestand zonder functies of classes.

```
1 '''
2 You are an AI documentation assistant, and your task is to generate
   a summary of the given Python file based on the code content.
3 The summary should include the following information:
4 - What the file does.
5 - What is the purpose of the file.
6 - What is the main functionality of the file.
7 - What the output is
8 - What it does when executed.
9 - Include the file name at the beginning of the summary.
10
11 An example of the output of your task is as follows:
12 Given the following code content:
13
14 ```python
15 from model import get_model
16 from train import train_top_layer, train_all_layers
17 if __name__ == '__main__':
18     model = get_model()
19     train_top_layer(model)
20 ```
21
22 The expected output of your task for the given code is the summary
   of the file:
23
24 ```python
25 """
26 Summary of file: main.py
27
28 This file contains the main functionality for a Python application.
29 It imports the get_model function from the model module and the
   train_top_layer and train_all_layers functions from the train
   module.
30 When executed, it gets a model using the get_model function and
   trains the top layer of the model using the train_top_layer
   function.
31 """
```

```

32  """
33
34  You are going to generate the summary based on the given code
    content of the file with filename: {filename}.
35  {code_content}
36  """

```

B.1.7. Project samenvatting

Prompt voor het genereren van een samenvatting van een project.

```

1  """
2  You are an AI documentation assistant, and your task is to generate
    a summary of the given Python project.
3  The summary should include the following information:
4  - What the project does.
5  - What files are included in the project. And what each file does.
    What functions and classes are defined in each file.
6  - A brief description of each class and function.
7  - Include the project name at the beginning of the summary.
8
9  You are going to generate the summary based on summaries of each
    file in the project.
10
11  Now it's your turn to generate the summary given the following
    project structure:
12  {project_name}
13
14  With the following folder structure:
15  {folder_structure}
16
17  And the following summaries of each file:
18  {summaries}
19  """

```

B.1.8. Project samenvatting per file

Prompt voor het genereren van een samenvatting van een project per bestand.

```

1  """
2      You are an AI documentation assistant, and your task is to
        generate a markdown summary of a file.

```



```

3     For the following file summary:
4     """
5     Summary of file: crop_images.py
6
7     This file contains the implementation of functions for cropping
      and padding images.
8
9     Functions:
10        crop_faces: Crop faces from an image using a specified
        bounding box.
11        crop_image: Crop a specified region from an image.
12        pad_img_to_fit_bbox: Pad an image to fit a specified bounding
        box.
13    """
14
15    The output should be:
16    - **crop_images.py**:
17        - Contains functions for cropping and padding images:
18        - `crop_faces`: Crop faces from an image using the given
        bounding boxes.
19        - `crop_image`: Crop a specific region from an image based
        on the provided coordinates.
20        - `pad_img_to_fit_bbox`: Pad an image to fit the specified
        bounding box.
21
22    You are going to generate the markdown summary for the file:
        {file} with the following summary:
23    {summary}
24    '''

```

B.2. Code

B.2.1. Vervangen van de code van een functie door de gegenereerde docstring. v1

```

1  def replace_functions(self, functions):
2      tree = self.tree
3      for node in ast.walk(tree):
4          if isinstance(node, (ast.FunctionDef, ast.AsyncFunctionDef))
              and node.name in functions:
5              new_func_def = ast.parse(functions[node.name]).body

```

```

6         tree.body.insert(tree.body.index(node), new_func_def)
7     self.tree = tree

```

B.2.2. Vervangen van de code van een functie door de gegenereerde docstring. v2

Versie 2 van de functie om de code van een functie te vervangen door de gegenereerde docstring.

```

1  def replace_functions(self, functions):
2      tree = self.tree
3      for node in ast.walk(tree):
4          if isinstance(node, ast.ClassDef):
5              for child_node in node.body:
6                  if isinstance(child_node, (ast.FunctionDef,
7                                          ast.AsyncFunctionDef)) and child_node.name in
8                      functions:
9                      new_func_def =
10                         ast.parse(functions[child_node.name]).body[0]
11                         new_func_def.body.extend(child_node.body)
12                         idx = node.body.index(child_node)
13                         node.body.insert(idx, new_func_def)
14                         node.body.remove(child_node)
15                         functions.pop(child_node.name)
16             elif isinstance(node, (ast.FunctionDef,
17                                   ast.AsyncFunctionDef)) and node.name in functions:
18                 new_func_def = ast.parse(functions[node.name]).body[0]
19                 new_func_def.body.extend(node.body)
20                 tree.body.insert(tree.body.index(node), new_func_def)
21                 tree.body.remove(node)
22                 functions.pop(node.name)
23     self.tree = tree

```

B.2.3. Vervangen van de code van een functie door de gegenereerde docstring. v3

```

1  def _replace_functions(self, node, functions):
2      if isinstance(node, (ast.FunctionDef, ast.AsyncFunctionDef)) and
3         node.name in functions:
4         new_func_def = ast.parse(functions[node.name]).body[0]
5         new_func_def.body.extend(node.body)

```

```
5     parent_node = self._get_parent_node(node)
6     index = parent_node.body.index(node)
7     parent_node.body.remove(node)
8     parent_node.body.insert(index, new_func_def)
9     functions.pop(node.name)
10 for child_node in ast.iter_child_nodes(node):
11     self._replace_functions(child_node, functions)
```

B.2.4. Genereren van de relaties tussen de verschillende bestanden

```
1 '''
2     You are an AI documentation assistant, and your task is to
3     generate a csv file containing the relations between the
4     files in a Python project.
5
6     For the given project structure and imports:
7     The imports are as follows:
8     '1_RPS_Game\\CMD_version\\main.py': 'import random',
9     '2_PyPassword_Generator\\CMD_version\\main.py': 'import
10    random', '3_Hangman_Game\\CMD_version\\images.py': '',
11    '3_Hangman_Game\\CMD_version\\main.py': 'import
12    requests\\nimport random\\nimport os\\nfrom images import
13    hangman_logo\\nfrom images import stages',
14    '4_Hangman_Game\\CMD_version\\stages.py': '',
15    '4_Hangman_Game\\CMD_version\\images.py': 'import
16    csv\\nimport matplotlib',
17    '4_Hangman_Game\\CMD_version\\main.py': 'import
18    random\\nimport os\\nfrom images import stages\\nfrom images
19    import logo'
20
21    The structure of the project is as follows:
```

```

9      '.': ['LICENSE', 'README.md'], '1_RPS_Game': [],
        '1_RPS_Game\\CMD_version':
        ['1_RPS_Game\\CMD_version\\main.py'],
        '2_PyPassword_Generator': [],
        '2_PyPassword_Generator\\CMD_version':
        ['2_PyPassword_Generator\\CMD_version\\main.py'],
        '3_Hangman_Game': [], '3_Hangman_Game\\CMD_version':
        ['3_Hangman_Game\\CMD_version\\images.py',
        '3_Hangman_Game\\CMD_version\\main.py'], '4_Hangman_Game':
        [], '4_Hangman_Game\\CMD_version':
        ['4_Hangman_Game\\CMD_version\\stages.py',
        '4_Hangman_Game\\CMD_version\\images.py',
        '4_Hangman_Game\\CMD_version\\main.py']

```

10

11 The expected output of your task is the following:

```
12 ```csv
```

```
13 File_Path,File_Name,Folder_Path,Uses_File
```

```
14 1_RPS_Game\\CMD_version\\main.py, main.py,1_RPS_Game\\CMD_version,[]
```

```
15 2_PyPassword_Generator\\CMD_version\\main.py,main.py,
```

```
    2_PyPassword_Generator\\CMD_version,[]
```

```
16 3_Hangman_Game\\CMD_version\\images.py,images.py,3_Hangman_Game\\CMD_version,[]
```

```
17 3_Hangman_Game\\CMD_version\\main.py,
```

```
    main.py,3_Hangman_Game\\CMD_version,['3_Hangman_Game.CMD_version.images']
```

```
18 4_Hangman_Game\\CMD_version\\stages.py,stages.py,4_Hangman_Game\\CMD_version,[]
```

```
19 4_Hangman_Game\\CMD_version\\images.py,images.py,4_Hangman_Game\\CMD_version,[]
```

```
20 4_Hangman_Game\\CMD_version\\main.py,main.py,4_Hangman_Game\\CMD_version,['4_Hangman_
```

```
21 ```
```

22

23 The Column "Uses File" should only contain the files where the
file imports functions from.

24 For example if the imports are:

```
25 ```python
```

```
26 Import csv
```

```
27 Import matplotlib
```

```
28 from images import open_image
```

```
29 from stages import stage1
```

```
30 ```
```

31 The Column "Uses File" should contain the file

```
'4_Hangman_Game\\CMD_version\\images.py' and
```

```
'4_Hangman_Game\\CMD_version\\stages.py'
```

```

32     Do your task given the following imports and structure of the
        project:
33
34     The imports are as follows:
35     {imports}
36
37     And the structure of the project is as follows:
38     {structure}
39
40     THE OUTPUT SHOULD BE A SINGLE CSV FILE CONTAINING THE RELATIONS
        BETWEEN THE FILES IN THE PROJECT.
41     '''

```

B.2.5. Functies voor het samenvatting van een bestand

```

1  def document_file(self, file_path, outfolder_path):
2      FDG = FileDocumenationGenerator(self.api_key,
        self.azure_endpoint, file_path, self.folder_path,
        outfolder_path)
3      FDG.generate_file_documentation()
4      return FDG
5
6  def generate_file_summaries(self, python_files):
7      for file in python_files:
8          print("Documenting file: ", file)
9          FDG = self.document_file(file, outfolder_path=self.outfolder)
10         self.summaries[file] = FDG.get_summary()
11         self.imports[file] = FDG.get_imports()

```

B.2.6. Generatie van een graph van de relaties tussen de bestanden

```

1  def generate_graph_html(self):
2      print("Generating graph html")
3      added_edges = set()
4      df = pd.read_csv(os.path.join(self.outfolder,
        'graph_relations.csv'))
5      net = Network(height="750px", width="100%",
        bgcolor="#222222", font_color="white")
6      net = Network(directed =True)
7      net.add_node("root", shape='star', label="")
8      for index, row in df.iterrows():

```

```

9         path = row['Folder_Path'].split("\\")
10        # Add nodes for each folder in the path
11        if len(path) > 1:
12            for i in range(len(path)-1):
13                path_id = "_".join(path[:i+1])
14                net.add_node(path_id, label=path[i], shape='box')
15                next_path_id = "_".join(path[:i+2])
16                net.add_node("_".join(path[:i+2]),
17                             label=path[i+1], shape='box')
18                edge = (path_id, next_path_id)
19                if edge not in added_edges:
20                    net.add_edge(path_id, next_path_id)
21                    added_edges.add(edge)
22            elif len(path) == 1:
23                net.add_node(path[0], label=path[0], shape='box')
24
25        # Add node for the file
26        file_path = row['File_Path'].split("\\")
27        file_id = "_".join(file_path)
28        parent_folder_id = "_".join(path)
29        net.add_node(file_id, label=file_path[-1])
30        edge = (parent_folder_id, file_id)
31        if edge not in added_edges:
32            net.add_edge(parent_folder_id, file_id)
33            added_edges.add(edge)
34
35        # Add edges for the root node
36        root_edge = ("root", path[0])
37        if root_edge not in added_edges:
38            net.add_edge("root", path[0])
39            added_edges.add(root_edge)
40
41    for index, row in df.iterrows():
42        file_id = "_".join(row['File_Path'].split("\\"))
43        # Add edges for the uses files
44        uses = row['Uses_File'].strip("[ ]")
45        if uses:
46            uses = uses.split(";")
47            for use_file in uses:
48                use_file_path = use_file.strip("'").split(".")
49                use_file_id = "_".join(use_file_path)+".py"

```

```
49         edge = (file_id, use_file_id)
50         if edge not in added_edges:
51             net.add_edge(file_id, use_file_id)
52             added_edges.add(edge)
53
54     path = os.path.join(self.outfolder, 'graph.html')
55     net.save_graph(path)
```

B.3. Zelfgedocumenteerde bestanden

B.3.1. Zelfgedocumenteerd bestand makkelijk niveau

```
1 def is_prime(n: int) -> bool:
2     """
3     Check if a number is prime.
4
5     Args:
6         n (int): The number to check.
7
8     Returns:
9         bool: True if the number is prime, False otherwise.
10    """
11    if n in [2, 3]:
12        return True
13    if (n == 1) or (n % 2 == 0):
14        return False
15    r = 3
16    while r * r ≤ n:
17        if n % r == 0:
18            return False
19        r += 2
20    return True
```

B.3.2. Zelfgedocumenteerd bestand gemiddeld niveau

```
1 import os
2 import cv2
3 import dlib
4 from matplotlib import pyplot as plt
5 import numpy as np
6 import config
```

```

7  detector = dlib.get_frontal_face_detector()
8
9  def crop_faces(plot_images: bool=False, max_images_to_plot: int=5):
10     """
11     Crop faces from images in the original images directory and save
12     them in the cropped images directory.
13
14     Args:
15         plot_images (bool): Whether to plot the cropped images.
16         Defaults to False.
17         max_images_to_plot (int): Maximum number of images to plot.
18         Defaults to 5.
19
20     Returns:
21         List[np.array]: List of good cropped images.
22     """
23     bad_crop_count = 0
24     if not os.path.exists(config.CROPPED_IMGS_DIR):
25         os.makedirs(config.CROPPED_IMGS_DIR)
26     print('Cropping faces and saving to %s' %
27           config.CROPPED_IMGS_DIR)
28     good_cropped_images = []
29     good_cropped_img_file_names = []
30     detected_cropped_images = []
31     original_images_detected = []
32     for file_name in sorted(os.listdir(config.ORIGINAL_IMGS_DIR)):
33         np_img = cv2.imread(os.path.join(config.ORIGINAL_IMGS_DIR,
34                                           file_name))
35         detected = detector(np_img, 1)
36         img_h, img_w, _ = np.shape(np_img)
37         original_images_detected.append(np_img)
38         if len(detected) != 1:
39             bad_crop_count += 1
40             continue
41         d = detected[0]
42         x1, y1, x2, y2, w, h = (d.left(), d.top(), d.right() + 1,
43                                d.bottom() + 1, d.width(), d.height())
44         xw1 = int(x1 - config.MARGIN * w)
45         yw1 = int(y1 - config.MARGIN * h)
46         xw2 = int(x2 + config.MARGIN * w)
47         yw2 = int(y2 + config.MARGIN * h)

```



```

42         cropped_img = crop_image(np_img, xw1, yw1, xw2, yw2)
43         norm_file_path = '%s/%s' % (config.CROPPED_IMGS_DIR,
            file_name)
44         cv2.imwrite(norm_file_path, cropped_img)
45         good_cropped_img_file_names.append(file_name)
46     with open(config.ORIGINAL_IMGS_INFO_FILE, 'r') as f:
47         column_headers = f.read().splitlines()[0]
48         all_imgs_info = f.read().splitlines()[1:]
49     cropped_imgs_info = [l for l in all_imgs_info if
        l.split(',')[ -1] in good_cropped_img_file_names]
50     with open(config.CROPPED_IMGS_INFO_FILE, 'w') as f:
51         f.write('%s\n' % column_headers)
52         for l in cropped_imgs_info:
53             f.write('%s\n' % l)
54     print('Cropped %d images and saved in %s - info in %s' %
        (len(original_images_detected), config.CROPPED_IMGS_DIR,
        config.CROPPED_IMGS_INFO_FILE))
55     print('Error detecting face in %d images - info in
        Data/unnormalized.txt' % bad_crop_count)
56     if plot_images:
57         print('Plotting images ... ')
58         img_index = 0
59         plot_index = 1
60         plot_n_cols = 3
61         plot_n_rows = len(original_images_detected) if
            len(original_images_detected) < max_images_to_plot else
            max_images_to_plot
62         for row in range(plot_n_rows):
63             plt.subplot(plot_n_rows, plot_n_cols, plot_index)
64
65             plt.imshow(original_images_detected[img_index].astype('uint8'))
66             plot_index += 1
67             plt.subplot(plot_n_rows, plot_n_cols, plot_index)
68             plt.imshow(detected_cropped_images[img_index])
69             plot_index += 1
70             plt.subplot(plot_n_rows, plot_n_cols, plot_index)
71             plt.imshow(good_cropped_images[img_index])
72             plot_index += 1
73             img_index += 1
74     plt.show()
75     return good_cropped_images

```

```
75
76 def crop_image(img, x1, y1, x2, y2):
77     """
78     Crop an image to the bounding box defined by the coordinates (x1,
79         y1, x2, y2).
80
81     Args:
82         img (np.ndarray): Input image.
83         x1 (int): x-coordinate of the top-left corner of the bounding
84             box.
85         y1 (int): y-coordinate of the top-left corner of the bounding
86             box.
87         x2 (int): x-coordinate of the bottom-right corner of the
88             bounding box.
89         y2 (int): y-coordinate of the bottom-right corner of the
90             bounding box.
91
92     Returns:
93         np.ndarray: Cropped image.
94     """
95     if x1 < 0 or y1 < 0 or x2 > img.shape[1] or (y2 > img.shape[0]):
96         img, x1, x2, y1, y2 = pad_img_to_fit_bbox(img, x1, x2, y1, y2)
97     return img[y1:y2, x1:x2, :]
98
99 def pad_img_to_fit_bbox(img, x1, x2, y1, y2):
100     """
101     Pad an image to fit a bounding box.
102
103     Args:
104         img (np.array): Input image.
105         x1 (int): x-coordinate of the top-left corner of the bounding
106             box.
107         x2 (int): x-coordinate of the bottom-right corner of the
108             bounding box.
109         y1 (int): y-coordinate of the top-left corner of the bounding
110             box.
111         y2 (int): y-coordinate of the bottom-right corner of the
112             bounding box.
113
114     Returns:
```

```

106         Tuple[np.array, int, int, int, int]: Padded image and updated
            coordinates.
107     """
108     img = cv2.copyMakeBorder(img, -min(0, y1), max(y2 -
            img.shape[0], 0), -min(0, x1), max(x2 - img.shape[1], 0),
            cv2.BORDER_REPLICATE)
109     y2 += -min(0, y1)
110     y1 += -min(0, y1)
111     x2 += -min(0, x1)
112     x1 += -min(0, x1)
113     return (img, x1, x2, y1, y2)
114
115 if __name__ == '__main__':
116     crop_faces()
117
118 """
119 Summary of file: crop_images.py
120
121 This file contains the implementation of functions to crop and pad
    images.
122
123 Functions:
124     crop_faces: Crop faces from an image based on the given bounding
        boxes.
125     crop_image: Crop an image to the bounding box defined by the
        coordinates (x1, y1, x2, y2).
126     pad_img_to_fit_bbox: Pad an image to fit a bounding box.
127 """

```

B.3.3. Zelfgedocumenteerd bestand moeilijk niveau

```

1 import csv
2
3 class CsvReader:
4     """
5     A class to read csv files
6
7     Methods:
8         readCsv(filename): Reads a csv file and returns the data in a
            list of lists
9

```

```

10     """
11     def readCsv(self, filename):
12         """
13         Reads a csv file and returns the data in a list of lists
14
15         Args:
16             filename (str): Name of the file to read
17
18         Returns:
19             list[list[str]]: List of lists containing the data from
20                             the csv file
21         """
22         self.rowData = []
23         self.lineCount = 0
24         with open(filename) as csvFile:
25             self.csvReader = csv.reader(csvFile, delimiter=',')
26             for row in self.csvReader:
27                 if self.lineCount == 0 or self.lineCount == 1:
28                     self.lineCount += 1
29                 else:
30                     self.rowData.append(row)
31                     self.lineCount += 1
32             return self.rowData
33     """
34     Summary of file CsvReader.py:
35
36     This file contains a class CsvReader that reads csv files.
37
38     Classes:
39         CsvReader: A class to read csv files
40
41     Methods:
42         readCsv: Reads a csv file and returns the data in a list of
43                 lists
44     """

```

B.4. Python bestanden geclassificeerd op moeilijkheidsgraad

B.4.1. Makkelijk

```
1 def is_prime(n):
2     if n in [2, 3]:
3         return True
4     if (n == 1) or (n % 2 == 0):
5         return False
6     r = 3
7     while r * r ≤ n:
8         if n % r == 0:
9             return False
10        r += 2
11    return True
```

B.4.2. Gemiddeld

```
1 import os
2 import cv2
3 import dlib
4 from matplotlib import pyplot as plt
5 import numpy as np
6 import config
7
8 detector = dlib.get_frontal_face_detector()
9
10
11 def crop_faces(plot_images=False, max_images_to_plot=5):
12     bad_crop_count = 0
13     if not os.path.exists(config.CROPPED_IMGS_DIR):
14         os.makedirs(config.CROPPED_IMGS_DIR)
15     print('Cropping faces and saving to %s' %
16           config.CROPPED_IMGS_DIR)
17     good_cropped_images = []
18     good_cropped_img_file_names = []
19     detected_cropped_images = []
20     original_images_detected = []
21     for file_name in sorted(os.listdir(config.ORIGINAL_IMGS_DIR)):
22         np_img =
23             cv2.imread(os.path.join(config.ORIGINAL_IMGS_DIR, file_name))
24         detected = detector(np_img, 1)
```

```

23     img_h, img_w, _ = np.shape(np_img)
24     original_images_detected.append(np_img)
25
26     if len(detected) != 1:
27         bad_crop_count += 1
28         continue
29
30     d = detected[0]
31     x1, y1, x2, y2, w, h = d.left(), d.top(), d.right() + 1,
        d.bottom() + 1, d.width(), d.height()
32     xw1 = int(x1 - config.MARGIN * w)
33     yw1 = int(y1 - config.MARGIN * h)
34     xw2 = int(x2 + config.MARGIN * w)
35     yw2 = int(y2 + config.MARGIN * h)
36     cropped_img = crop_image(np_img, xw1, yw1, xw2, yw2)
37     norm_file_path = '%s/%s' % (config.CROPPED_IMGS_DIR,
        file_name)
38     cv2.imwrite(norm_file_path, cropped_img)
39
40     good_cropped_img_file_names.append(file_name)
41
42     # save info of good cropped images
43     with open(config.ORIGINAL_IMGS_INFO_FILE, 'r') as f:
44         column_headers = f.read().splitlines()[0]
45         all_imgs_info = f.read().splitlines()[1:]
46     cropped_imgs_info = [l for l in all_imgs_info if
        l.split(',')[ -1] in good_cropped_img_file_names]
47
48     with open(config.CROPPED_IMGS_INFO_FILE, 'w') as f:
49         f.write('%s\n' % column_headers)
50         for l in cropped_imgs_info:
51             f.write('%s\n' % l)
52
53     print('Cropped %d images and saved in %s - info in %s' %
        (len(original_images_detected), config.CROPPED_IMGS_DIR,
        config.CROPPED_IMGS_INFO_FILE))
54     print('Error detecting face in %d images - info in
        Data/unnormalized.txt' % bad_crop_count)
55
56     if plot_images:
57         print('Plotting images ... ')

```

```
58     img_index = 0
59     plot_index = 1
60     plot_n_cols = 3
61     plot_n_rows = len(original_images_detected) if
        len(original_images_detected) < max_images_to_plot else
        max_images_to_plot
62     for row in range(plot_n_rows):
63         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
64
65         plt.imshow(original_images_detected[img_index].astype('uint8'))
66         plot_index += 1
67
68         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
69         plt.imshow(detected_cropped_images[img_index])
70         plot_index += 1
71
72         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
73         plt.imshow(good_cropped_images[img_index])
74         plot_index += 1
75
76         img_index += 1
77     plt.show()
78     return good_cropped_images
79
80
81 # image cropping method taken from:
82 #
83     https://stackoverflow.com/questions/15589517/how-to-crop-an-image-in-opencv-us
84 def crop_image(img, x1, y1, x2, y2):
85     if x1 < 0 or y1 < 0 or x2 > img.shape[1] or y2 > img.shape[0]:
86         img, x1, x2, y1, y2 = pad_img_to_fit_bbox(img, x1, x2, y1, y2)
87     return img[y1:y2, x1:x2, :]
88
89 def pad_img_to_fit_bbox(img, x1, x2, y1, y2):
90     img = cv2.copyMakeBorder(img, -min(0, y1), max(y2 -
91                                     img.shape[0], 0),
92                             -min(0, x1), max(x2 - img.shape[1], 0),
93                             cv2.BORDER_REPLICATE)
94     y2 += -min(0, y1)
95     y1 += -min(0, y1)
```

```
93     x2 += -min(0, x1)
94     x1 += -min(0, x1)
95     return img, x1, x2, y1, y2
96
97 if __name__ == '__main__':
98     crop_faces()
```

B.4.3. Moeilijk

```
1 import csv
2
3 class CsvReader:
4     def readCsv(self, filename):
5         self.rowData = []
6         self.lineCount = 0
7         with open(filename) as csvFile:
8             self.csvReader = csv.reader(csvFile, delimiter=',')
9             for row in self.csvReader:
10                 if self.lineCount == 0 or self.lineCount == 1:
11                     self.lineCount += 1
12                 else:
13                     self.rowData.append(row)
14                     self.lineCount += 1
15         return self.rowData
```

B.4.4. Extreem moeilijk

```
1 import inspect
2 import os
3 import sys
4 import time
5 from dataclasses import dataclass
6
7 import tiktoken
8 from openai import APIConnectionError, OpenAI
9
10 from repo_agent.doc_meta_info import DocItem
11 from repo_agent.log import logger
12 from repo_agent.prompt import SYS_PROMPT, USR_PROMPT
13 from repo_agent.settings import max_input_tokens_map, setting
14
```



```
15
16 def get_import_statements():
17     source_lines = inspect.getsourcelines(sys.modules[__name__])[0]
18     import_lines = [
19         line
20         for line in source_lines
21         if line.strip().startswith("import") or
22            line.strip().startswith("from")
23     ]
24     return import_lines
25
26 @dataclass
27 class ResponseMessage:
28     content: str
29
30 class ChatEngine:
31     """
32     ChatEngine is used to generate the doc of functions or classes.
33     """
34
35     def __init__(self, project_manager):
36         self.project_manager = project_manager
37
38     def num_tokens_from_string(self, string: str,
39                               encoding_name="cl100k_base") -> int:
40         """Returns the number of tokens in a text string."""
41         encoding = tiktoken.get_encoding(encoding_name)
42         num_tokens = len(encoding.encode(string))
43         return num_tokens
44
45     def reduce_input_length(self, shorten_attempt, prompt_data):
46         """
47         Reduces the length of the input prompts by modifying the
48         sys_prompt contents.
49         """
50         logger.info(
51             f"Attempt {shorten_attempt + 1} / 2 to reduce the length
52             of the messages."
53         )
```

```

52         if shorten_attempt == 0:
53             # First attempt, remove project_structure and
54             # project_structure_prefix
55             prompt_data.project_structure = ""
56             prompt_data.project_structure_prefix = ""
57         elif shorten_attempt == 1:
58             # Second attempt, further remove caller and callee
59             # (reference) information
60             prompt_data.project_structure = ""
61             prompt_data.project_structure_prefix = ""
62             prompt_data.referenced = False
63             prompt_data.referencer_content = ""
64             prompt_data.reference_letter = ""
65             prompt_data.combine_ref_situation = ""
66
67         # Update sys_prompt
68         sys_prompt = SYS_PROMPT.format(**prompt_data)
69
70         return sys_prompt
71
72     def generate_response(self, model, sys_prompt, usr_prompt,
73                           max_tokens):
74         client = OpenAI(
75             api_key=setting.chat_completion.openai_api_key.get_secret_value(),
76             base_url=str(setting.chat_completion.base_url),
77             timeout=setting.chat_completion.request_timeout,
78         )
79
80         messages = [
81             {"role": "system", "content": sys_prompt},
82             {"role": "user", "content": usr_prompt},
83         ]
84
85         response = client.chat.completions.create(
86             model=model,
87             messages=messages,
88             temperature=setting.chat_completion.temperature,
89             max_tokens=max_tokens,
90         )

```

```
89
90     response_message = response.choices[0].message
91
92     return response_message
93
94 def attempt_generate_response(
95     self, model, sys_prompt, usr_prompt, max_tokens,
96     max_attempts=5
97 ):
98     attempt = 0
99     while attempt < max_attempts:
100         try:
101             response_message = self.generate_response(
102                 model, sys_prompt, usr_prompt, max_tokens
103             )
104
105             if response_message is None:
106                 attempt += 1
107                 continue
108             return response_message
109
110         except APIConnectionError as e:
111             logger.error(
112                 f"Connection error: {e}. Attempt {attempt + 1} of
113                 {max_attempts}"
114             )
115             # Retry after 7 seconds
116             time.sleep(7)
117             attempt += 1
118             if attempt == max_attempts:
119                 raise
120             else:
121                 continue # Try to request again
122
123     except Exception as e:
124         logger.error(
125             f"An unknown error occurred: {e}. \nAttempt
126             {attempt + 1} of {max_attempts}"
127         )
128         # Retry after 10 seconds
129         time.sleep(10)
```

```

127         attempt += 1
128         if attempt == max_attempts:
129             response_message = ResponseMessage(
130                 "An unknown error occurred while generating
                    this documentation after many tries."
131             )
132         return response_message
133
134     def generate_doc(self, doc_item: DocItem, file_handler):
135         code_info = doc_item.content
136         referenced = len(doc_item.who_reference_me) > 0
137
138         code_type = code_info["type"]
139         code_name = code_info["name"]
140         code_content = code_info["code_content"]
141         have_return = code_info["have_return"]
142         who_reference_me = doc_item.who_reference_me_name_list
143         reference_who = doc_item.reference_who_name_list
144         file_path = doc_item.get_full_name()
145         doc_item_path = os.path.join(file_path, code_name)
146
147         project_structure = self.project_manager.build_path_tree(
148             who_reference_me, reference_who, doc_item_path
149         )
150
151         # project_manager =
152             ProjectManager(repo_path=file_handler.repo_path,
153                             project_hierarchy=file_handler.project_hierarchy)
154         # project_structure = project_manager.get_project_structure()
155         # file_path = os.path.join(file_handler.repo_path,
156             file_handler.file_path)
157         # code_from_referencer =
158             get_code_from_json(project_manager.project_hierarchy,
159                             referencer) #
160         # referenced = True if len(code_from_referencer) > 0 else
161             False
162         # referencer_content = '\n'.join([f'File_Path:{file_path}\n'
163             + '\n'.join([f'Corresponding code as
164                 follows:\n{code}\n[End of this part of code]' for code
165                 in codes])] + f'\n[End of {file_path}]' for file_path,
166                 codes in code_from_referencer.items()))

```

```
157
158     def get_referenced_prompt(doc_item: DocItem) -> str:
159         if len(doc_item.reference_who) == 0:
160             return ""
161         prompt = [
162             """As you can see, the code calls the following
163             objects, their code and docs are as following:"""
164         ]
165         for k, reference_item in
166             enumerate(doc_item.reference_who):
167             instance_prompt = (
168                 f"""obj:
169                 {reference_item.get_full_name()}\nDocument:
170                 \n{reference_item.md_content[-1]} if
171                 len(reference_item.md_content) > 0 else
172                 'None'}\nRaw
173                 code:```\n{reference_item.content['code_content']}
174                 if 'code_content' in
175                 reference_item.content.keys() else
176                 ''}\n```"""
177                 + "=" * 10
178             )
179             prompt.append(instance_prompt)
180         return "\n".join(prompt)
181
182     def get_referencer_prompt(doc_item: DocItem) -> str:
183         if len(doc_item.who_reference_me) == 0:
184             return ""
185         prompt = [
186             """Also, the code has been called by the following
187             objects, their code and docs are as following:"""
188         ]
189         for k, referencer_item in
190             enumerate(doc_item.who_reference_me):
191             instance_prompt = (
```

```

180         f"""obj:
            {referencer_item.get_full_name()}\nDocument:
            \n{referencer_item.md_content[-1] if
            len(referencer_item.md_content) > 0 else
            'None'}\nRaw
            code:``\n{referencer_item.content['code_content']}
            if 'code_content' in
            referencer_item.content.keys() else
            'None'}\n``"""
181         + "=" * 10
182     )
183     prompt.append(instance_prompt)
184     return "\n".join(prompt)
185
186 def get_relationship_description(referencer_content,
187     reference_letter):
188     if referencer_content and reference_letter:
189         return "And please include the reference relationship
190             with its callers and callees in the project from
191             a functional perspective"
192     elif referencer_content:
193         return "And please include the relationship with its
194             callers in the project from a functional
195             perspective."
196     elif reference_letter:
197         return "And please include the relationship with its
198             callees in the project from a functional
199             perspective."
200     else:
201         return ""
202
203 max_tokens = setting.project.max_document_tokens
204
205 code_type_tell = "Class" if code_type == "ClassDef" else
206     "Function"
207 parameters_or_attribute = (
208     "attributes" if code_type == "ClassDef" else "parameters"
209 )
210 have_return_tell = (
211     "**Output Example**: Mock up a possible appearance of the
212     code's return value."

```

```
204         if have_return
205         else ""
206     )
207     # reference_letter = "This object is called in the following
        files, the file paths and corresponding calling parts of
        the code are as follows:" if referenced else ""
208     combine_ref_situation = (
209         "and combine it with its calling situation in the
        project,"
210         if referenced
211         else ""
212     )
213
214     referencer_content = get_referencer_prompt(doc_item)
215     reference_letter = get_referenced_prompt(doc_item)
216     has_relationship = get_relationship_description(
217         referencer_content, reference_letter
218     )
219
220     project_structure_prefix = ", and the related hierarchical
        structure of this project is as follows (The current
        object is marked with an *):"
221
222     prompt_data = {
223         "combine_ref_situation": combine_ref_situation,
224         "file_path": file_path,
225         "project_structure_prefix": project_structure_prefix,
226         "project_structure": project_structure,
227         "code_type_tell": code_type_tell,
228         "code_name": code_name,
229         "code_content": code_content,
230         "have_return_tell": have_return_tell,
231         "has_relationship": has_relationship,
232         "reference_letter": reference_letter,
233         "referencer_content": referencer_content,
234         "parameters_or_attribute": parameters_or_attribute,
235         "language": setting.project.language,
236     }
237
238     sys_prompt = SYS_PROMPT.format(**prompt_data)
239
```

```
240         usr_prompt =
            USR_PROMPT.format(language=setting.project.language)
241
242         model = setting.chat_completion.model
243         max_input_length = max_input_tokens_map.get(model, 4096) -
            max_tokens
244
245         total_tokens = self.num_tokens_from_string(
246             sys_prompt
247         ) + self.num_tokens_from_string(usr_prompt)
248
249         if total_tokens ≥ max_input_length:
250             larger_models = {
251                 k: v
252                 for k, v in max_input_tokens_map.items()
253                 if (v - max_tokens) > total_tokens
254             }
255             for model_name, max_input_length in larger_models.items():
256                 if max_input_length - max_tokens > total_tokens:
257                     try:
258                         # Attempt to make a request with the larger
259                         # model
260                         logger.info(
261                             f"Trying model {model_name} for
262                             large-context processing."
263                         )
264                         response_message =
265                             self.attempt_generate_response(
266                                 model_name, sys_prompt, usr_prompt,
267                                 max_tokens
268                             )
269                         return response_message
270                     except Exception as e:
271                         continue # Try the next model
272             # If no larger models succeed, fallback to original model
273             for shorten_attempt in range(2):
274                 shorten_success = False
275                 sys_prompt = self.reduce_input_length(shorten_attempt,
276                                                         prompt_data)
277                 total_tokens = self.num_tokens_from_string(
278                     sys_prompt
```



```

274         ) + self.num_tokens_from_string(usr_prompt)
275         if total_tokens < max_input_length:
276             shorten_success = True
277             response_message = self.attempt_generate_response(
278                 model, sys_prompt, usr_prompt, max_tokens
279             )
280
281         if not shorten_success:
282             response_message = ResponseMessage(
283                 "Tried to generate the document, but the code is
284                 too long to process."
285             )
286             return response_message
287
288         else:
289             response_message = self.attempt_generate_response(
290                 model, sys_prompt, usr_prompt, max_tokens
291             )
292
293         return response_message

```

B.5. Uitkomst documentatie van de Python bestanden

B.5.1. Uitkomst documentatie van gemiddeld bestand

```

1  import os
2  import cv2
3  import dlib
4  from matplotlib import pyplot as plt
5  import numpy as np
6  import config
7  detector = dlib.get_frontal_face_detector()
8
9  def crop_faces(plot_images=False, max_images_to_plot=5):
10
11      def crop_faces(plot_images: bool=False, max_images_to_plot:
12          int=5) -> List[np.ndarray]:
13          """
14              Crop faces from original images and save the cropped images.
15
16              Args:

```

```

16         plot_images (bool, optional): Whether to plot the cropped
           images. Defaults to False.
17         max_images_to_plot (int, optional): Maximum number of
           images to plot. Defaults to 5.
18
19     Returns:
20         List[np.ndarray]: List of good cropped images.
21     """
22     bad_crop_count = 0
23     if not os.path.exists(config.CROPPED_IMGS_DIR):
24         os.makedirs(config.CROPPED_IMGS_DIR)
25     print('Cropping faces and saving to %s' %
           config.CROPPED_IMGS_DIR)
26     good_cropped_images = []
27     good_cropped_img_file_names = []
28     detected_cropped_images = []
29     original_images_detected = []
30     for file_name in
        sorted(os.listdir(config.ORIGINAL_IMGS_DIR)):
31         np_img =
            cv2.imread(os.path.join(config.ORIGINAL_IMGS_DIR,
                                     file_name))
32         detected = detector(np_img, 1)
33         img_h, img_w, _ = np.shape(np_img)
34         original_images_detected.append(np_img)
35         if len(detected) != 1:
36             bad_crop_count += 1
37             continue
38         d = detected[0]
39         x1, y1, x2, y2, w, h = (d.left(), d.top(), d.right() + 1,
                                d.bottom() + 1, d.width(), d.height())
40         xw1 = int(x1 - config.MARGIN * w)
41         yw1 = int(y1 - config.MARGIN * h)
42         xw2 = int(x2 + config.MARGIN * w)
43         yw2 = int(y2 + config.MARGIN * h)
44         cropped_img = crop_image(np_img, xw1, yw1, xw2, yw2)
45         norm_file_path = '%s/%s' % (config.CROPPED_IMGS_DIR,
                                       file_name)
46         cv2.imwrite(norm_file_path, cropped_img)
47         good_cropped_img_file_names.append(file_name)
48     with open(config.ORIGINAL_IMGS_INFO_FILE, 'r') as f:

```

```

49         column_headers = f.read().splitlines()[0]
50         all_imgs_info = f.read().splitlines()[1:]
51         cropped_imgs_info = [l for l in all_imgs_info if
52                               l.split(',')[0] in good_cropped_img_file_names]
53         with open(config.CROPPED_IMGS_INFO_FILE, 'w') as f:
54             f.write('%s\n' % column_headers)
55             for l in cropped_imgs_info:
56                 f.write('%s\n' % l)
57         print('Cropped %d images and saved in %s - info in %s' %
58               (len(original_images_detected), config.CROPPED_IMGS_DIR,
59                config.CROPPED_IMGS_INFO_FILE))
60         print('Error detecting face in %d images - info in
61               Data/unnormalized.txt' % bad_crop_count)
62         if plot_images:
63             print('Plotting images ... ')
64             img_index = 0
65             plot_index = 1
66             plot_n_cols = 3
67             plot_n_rows = len(original_images_detected) if
68                             len(original_images_detected) < max_images_to_plot
69                             else max_images_to_plot
70             for row in range(plot_n_rows):
71                 plt.subplot(plot_n_rows, plot_n_cols, plot_index)
72                 plt.imshow(original_images_detected[img_index].astype('uint8'))
73                 plot_index += 1
74                 plt.subplot(plot_n_rows, plot_n_cols, plot_index)
75                 plt.imshow(detected_cropped_images[img_index])
76                 plot_index += 1
77                 plt.subplot(plot_n_rows, plot_n_cols, plot_index)
78                 plt.imshow(good_cropped_images[img_index])
79                 plot_index += 1
80                 img_index += 1
81         plt.show()
82         return good_cropped_images
83
84 def crop_image(img, x1, y1, x2, y2):
85
86     def crop_image(img: ndarray, x1: int, y1: int, x2: int, y2: int)
87         -> ndarray:
88         """

```

```

82         Crop the input image to the specified dimensions.
83
84     Args:
85         img (ndarray): The input image.
86         x1 (int): The starting x-coordinate for cropping.
87         y1 (int): The starting y-coordinate for cropping.
88         x2 (int): The ending x-coordinate for cropping.
89         y2 (int): The ending y-coordinate for cropping.
90
91     Returns:
92         ndarray: The cropped image.
93     """
94     if x1 < 0 or y1 < 0 or x2 > img.shape[1] or (y2 >
95         img.shape[0]):
96         img, x1, x2, y1, y2 = pad_img_to_fit_bbox(img, x1, x2,
97             y1, y2)
98     return img[y1:y2, x1:x2, :]
99
100 def pad_img_to_fit_bbox(img, x1, x2, y1, y2):
101
102     def pad_img_to_fit_bbox(img: numpy.ndarray, x1: int, x2: int,
103         y1: int, y2: int) -> tuple:
104         """
105         Pads an image to fit a bounding box.
106
107         Args:
108             img (numpy.ndarray): The image to pad.
109             x1 (int): Left boundary of the bounding box.
110             x2 (int): Right boundary of the bounding box.
111             y1 (int): Top boundary of the bounding box.
112             y2 (int): Bottom boundary of the bounding box.
113
114         Returns:
115             tuple: A tuple containing the padded image and the updated
116                 bounding box coordinates (x1, x2, y1, y2).
117         """
118         img = cv2.copyMakeBorder(img, -min(0, y1), max(y2 -
119             img.shape[0], 0), -min(0, x1), max(x2 - img.shape[1],
120             0), cv2.BORDER_REPLICATE)
121         y2 += -min(0, y1)
122         y1 += -min(0, y1)

```

```

117         x2 += -min(0, x1)
118         x1 += -min(0, x1)
119         return (img, x1, x2, y1, y2)
120 if __name__ == '__main__':
121     crop_faces()

```

B.6. Evaluatie bestand documentatie

B.6.1. Uitkomst van bestand documentatie door eigen tool

```

1  import os
2  import cv2
3  import dlib
4  from matplotlib import pyplot as plt
5  import numpy as np
6  import config
7  detector = dlib.get_frontal_face_detector()
8
9  def crop_faces(plot_images: bool=False, max_images_to_plot: int=5)
   -> List[np.ndarray]:
10      """
11      Crop faces from the original images and save the cropped images.
12
13      Args:
14          plot_images (bool, optional): Whether to plot the images.
15          Defaults to False.
16          max_images_to_plot (int, optional): Maximum number of images
17          to plot. Defaults to 5.
18
19      Returns:
20          List[np.ndarray]: List of good cropped images.
21      """
22      bad_crop_count = 0
23      if not os.path.exists(config.CROPPED_IMGS_DIR):
24          os.makedirs(config.CROPPED_IMGS_DIR)
25      print('Cropping faces and saving to %s' %
26            config.CROPPED_IMGS_DIR)
27      good_cropped_images = []
28      good_cropped_img_file_names = []
29      detected_cropped_images = []
30      original_images_detected = []

```

```

28     for file_name in sorted(os.listdir(config.ORIGINAL_IMGS_DIR)):
29         np_img = cv2.imread(os.path.join(config.ORIGINAL_IMGS_DIR,
30             file_name))
31         detected = detector(np_img, 1)
32         img_h, img_w, _ = np.shape(np_img)
33         original_images_detected.append(np_img)
34         if len(detected) != 1:
35             bad_crop_count += 1
36             continue
37         d = detected[0]
38         x1, y1, x2, y2, w, h = (d.left(), d.top(), d.right() + 1,
39             d.bottom() + 1, d.width(), d.height())
40         xw1 = int(x1 - config.MARGIN * w)
41         yw1 = int(y1 - config.MARGIN * h)
42         xw2 = int(x2 + config.MARGIN * w)
43         yw2 = int(y2 + config.MARGIN * h)
44         cropped_img = crop_image(np_img, xw1, yw1, xw2, yw2)
45         norm_file_path = '%s/%s' % (config.CROPPED_IMGS_DIR,
46             file_name)
47         cv2.imwrite(norm_file_path, cropped_img)
48         good_cropped_img_file_names.append(file_name)
49     with open(config.ORIGINAL_IMGS_INFO_FILE, 'r') as f:
50         column_headers = f.read().splitlines()[0]
51         all_imgs_info = f.read().splitlines()[1:]
52     cropped_imgs_info = [l for l in all_imgs_info if
53         l.split(',')[0] in good_cropped_img_file_names]
54     with open(config.CROPPED_IMGS_INFO_FILE, 'w') as f:
55         f.write('%s\n' % column_headers)
56         for l in cropped_imgs_info:
57             f.write('%s\n' % l)
58     print('Cropped %d images and saved in %s - info in %s' %
59         (len(original_images_detected), config.CROPPED_IMGS_DIR,
60         config.CROPPED_IMGS_INFO_FILE))
61     print('Error detecting face in %d images - info in
62         Data/unnormalized.txt' % bad_crop_count)
63     if plot_images:
64         print('Plotting images ... ')
65         img_index = 0
66         plot_index = 1
67         plot_n_cols = 3

```

```
61     plot_n_rows = len(original_images_detected) if
        len(original_images_detected) < max_images_to_plot else
        max_images_to_plot
62     for row in range(plot_n_rows):
63         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
64
        plt.imshow(original_images_detected[img_index].astype('uint8'))
65         plot_index += 1
66         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
67         plt.imshow(detected_cropped_images[img_index])
68         plot_index += 1
69         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
70         plt.imshow(good_cropped_images[img_index])
71         plot_index += 1
72         img_index += 1
73     plt.show()
74     return good_cropped_images
75
76 def crop_image(img: np.ndarray, x1: int, y1: int, x2: int, y2: int)
    -> np.ndarray:
77     """
78     Crop a region from the input image based on the specified
        coordinates.
79
80     Args:
81         img (np.ndarray): The input image.
82         x1 (int): The starting x-coordinate of the region to be
            cropped.
83         y1 (int): The starting y-coordinate of the region to be
            cropped.
84         x2 (int): The ending x-coordinate of the region to be cropped.
85         y2 (int): The ending y-coordinate of the region to be cropped.
86
87     Returns:
88         np.ndarray: The cropped region of the image.
89     """
90     if x1 < 0 or y1 < 0 or x2 > img.shape[1] or (y2 > img.shape[0]):
91         img, x1, x2, y1, y2 = pad_img_to_fit_bbox(img, x1, x2, y1, y2)
92     return img[y1:y2, x1:x2, :]
```

```

94 def pad_img_to_fit_bbox(img: np.array, x1: int, x2: int, y1: int,
95    y2: int) -> Tuple[np.array, int, int, int, int]:
96     """
97     Pad the image to fit the specified bounding box coordinates.
98     Args:
99         img (np.array): The input image.
100        x1 (int): The x-coordinate of the left side of the bounding
101        box.
102        x2 (int): The x-coordinate of the right side of the bounding
103        box.
104        y1 (int): The y-coordinate of the top side of the bounding
105        box.
106        y2 (int): The y-coordinate of the bottom side of the bounding
107        box.
108
109    Returns:
110        Tuple[np.array, int, int, int, int]: The padded image and
111        updated coordinates of the bounding box.
112    """
113    img = cv2.copyMakeBorder(img, -min(0, y1), max(y2 -
114    img.shape[0], 0), -min(0, x1), max(x2 - img.shape[1], 0),
115    cv2.BORDER_REPLICATE)
116    y2 += -min(0, y1)
117    y1 += -min(0, y1)
118    x2 += -min(0, x1)
119    x1 += -min(0, x1)
120    return (img, x1, x2, y1, y2)
121 if __name__ == '__main__':
122     crop_faces()
123
124 """
125 Summary of file: crop_images.py
126
127 This file contains the implementation of functions to crop and pad
128 images.
129
130 Functions:
131     crop_faces: Crop faces from an image and return a list of cropped
132     faces.

```



```
125     crop_image: Crop a specified region from an image.
126     pad_img_to_fit_bbox: Pad an image to fit a specified bounding
        box.
127 """
```

B.6.2. Zelfgedocumenteerd bestand gemiddeld niveau

```
1  import os
2  import cv2
3  import dlib
4  from matplotlib import pyplot as plt
5  import numpy as np
6  import config
7  detector = dlib.get_frontal_face_detector()
8
9  def crop_faces(plot_images: bool=False, max_images_to_plot: int=5):
10     """
11     Crop faces from images in the original images directory and save
        them in the cropped images directory.
12
13     Args:
14         plot_images (bool): Whether to plot the cropped images.
        Defaults to False.
15         max_images_to_plot (int): Maximum number of images to plot.
        Defaults to 5.
16
17     Returns:
18         List[np.array]: List of good cropped images.
19     """
20     bad_crop_count = 0
21     if not os.path.exists(config.CROPPED_IMGS_DIR):
22         os.makedirs(config.CROPPED_IMGS_DIR)
23     print('Cropping faces and saving to %s' %
        config.CROPPED_IMGS_DIR)
24     good_cropped_images = []
25     good_cropped_img_file_names = []
26     detected_cropped_images = []
27     original_images_detected = []
28     for file_name in sorted(os.listdir(config.ORIGINAL_IMGS_DIR)):
29         np_img = cv2.imread(os.path.join(config.ORIGINAL_IMGS_DIR,
            file_name))
```

```

30     detected = detector(np_img, 1)
31     img_h, img_w, _ = np.shape(np_img)
32     original_images_detected.append(np_img)
33     if len(detected) != 1:
34         bad_crop_count += 1
35         continue
36     d = detected[0]
37     x1, y1, x2, y2, w, h = (d.left(), d.top(), d.right() + 1,
38                             d.bottom() + 1, d.width(), d.height())
39     xw1 = int(x1 - config.MARGIN * w)
40     yw1 = int(y1 - config.MARGIN * h)
41     xw2 = int(x2 + config.MARGIN * w)
42     yw2 = int(y2 + config.MARGIN * h)
43     cropped_img = crop_image(np_img, xw1, yw1, xw2, yw2)
44     norm_file_path = '%s/%s' % (config.CROPPED_IMGS_DIR,
45                                 file_name)
46     cv2.imwrite(norm_file_path, cropped_img)
47     good_cropped_img_file_names.append(file_name)
48 with open(config.ORIGINAL_IMGS_INFO_FILE, 'r') as f:
49     column_headers = f.read().splitlines()[0]
50     all_imgs_info = f.read().splitlines()[1:]
51     cropped_imgs_info = [l for l in all_imgs_info if
52                           l.split(',')[1] in good_cropped_img_file_names]
53 with open(config.CROPPED_IMGS_INFO_FILE, 'w') as f:
54     f.write('%s\n' % column_headers)
55     for l in cropped_imgs_info:
56         f.write('%s\n' % l)
57 print('Cropped %d images and saved in %s - info in %s' %
58       (len(original_images_detected), config.CROPPED_IMGS_DIR,
59        config.CROPPED_IMGS_INFO_FILE))
60 print('Error detecting face in %d images - info in
61       Data/unnormalized.txt' % bad_crop_count)
62 if plot_images:
63     print('Plotting images... ')
64     img_index = 0
65     plot_index = 1
66     plot_n_cols = 3
67     plot_n_rows = len(original_images_detected) if
68                     len(original_images_detected) < max_images_to_plot else
69                     max_images_to_plot
70     for row in range(plot_n_rows):

```

```

63         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
64
65         plt.imshow(original_images_detected[img_index].astype('uint8'))
66         plot_index += 1
67         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
68         plt.imshow(detected_cropped_images[img_index])
69         plot_index += 1
70         plt.subplot(plot_n_rows, plot_n_cols, plot_index)
71         plt.imshow(good_cropped_images[img_index])
72         plot_index += 1
73         img_index += 1
74     plt.show()
75     return good_cropped_images
76
77 def crop_image(img, x1, y1, x2, y2):
78     """
79     Crop an image to the bounding box defined by the coordinates (x1,
80     y1, x2, y2).
81
82     Args:
83         img (np.ndarray): Input image.
84         x1 (int): x-coordinate of the top-left corner of the bounding
85         box.
86         y1 (int): y-coordinate of the top-left corner of the bounding
87         box.
88         x2 (int): x-coordinate of the bottom-right corner of the
89         bounding box.
90         y2 (int): y-coordinate of the bottom-right corner of the
91         bounding box.
92
93     Returns:
94         np.ndarray: Cropped image.
95     """
96     if x1 < 0 or y1 < 0 or x2 > img.shape[1] or (y2 > img.shape[0]):
97         img, x1, x2, y1, y2 = pad_img_to_fit_bbox(img, x1, x2, y1, y2)
98     return img[y1:y2, x1:x2, :]
99
100 def pad_img_to_fit_bbox(img, x1, x2, y1, y2):
101     """
102     Pad an image to fit a bounding box.

```

```

98     Args:
99         img (np.array): Input image.
100        x1 (int): x-coordinate of the top-left corner of the bounding
            box.
101        x2 (int): x-coordinate of the bottom-right corner of the
            bounding box.
102        y1 (int): y-coordinate of the top-left corner of the bounding
            box.
103        y2 (int): y-coordinate of the bottom-right corner of the
            bounding box.
104
105     Returns:
106         Tuple[np.array, int, int, int, int]: Padded image and updated
            coordinates.
107     """
108     img = cv2.copyMakeBorder(img, -min(0, y1), max(y2 -
            img.shape[0], 0), -min(0, x1), max(x2 - img.shape[1], 0),
            cv2.BORDER_REPLICATE)
109     y2 += -min(0, y1)
110     y1 += -min(0, y1)
111     x2 += -min(0, x1)
112     x1 += -min(0, x1)
113     return (img, x1, x2, y1, y2)
114
115 if __name__ == '__main__':
116     crop_faces()
117
118 """
119 Summary of file: crop_images.py
120
121 This file contains the implementation of functions to crop and pad
    images.
122
123 Functions:
124     crop_faces: Crop faces from an image based on the given bounding
        boxes.
125     crop_image: Crop an image to the bounding box defined by the
        coordinates (x1, y1, x2, y2).
126     pad_img_to_fit_bbox: Pad an image to fit a bounding box.
127 """

```

Bibliografie

- "Roslyn", dotnet (computersoft.). (z.d.). <https://github.com/dotnet/roslyn>
- Anthropic. (2023, mei 14). *Introducing Claude*. <https://www.anthropic.com/news/introducing-claude>
- ArtificialAnalysis (Red.). (2024). *Comparison of Models: Quality, Performance Price Analysis*. Verkregen mei 19, 2024, van <https://artificialanalysis.ai/models>
- Bailey, C. (2024). *Type Hinting*. Verkregen mei 9, 2024, van <https://realpython.com/lessons/type-hinting/>
- Beelen, J. (2023, juni 22). *Hoe werken Large Language Models (LLM)?* <https://www.linkedin.com/pulse/hoe-werken-large-language-models-llm-jeroen-beelen/?originalSubdomain=nl>
- Cacic, M. (2023, september 6). *Pre-training vs Fine-Tuning vs In-Context Learning of Large Language Models*. <https://www.entrypoin.ai.com/blog/pre-training-vs-fine-tuning-vs-in-context-learning-of-large-language-models/>
- Code Quality (Red.). (2024, april 4). *Code Documentation Best Practices and Standards: A Complete Guide*. Verkregen mei 19, 2024, van <https://blog.codacy.com/code-documentation>
- CodeCat.AI. (2024). *AI Docstring Generator*. <https://www.codecat.ai/ai-docstring-generator>
- Das, S. (2024, januari 25). *Fine Tune Large Language Model (LLM) on a Custom Dataset with QLoRA*. <https://dassum.medium.com/fine-tune-large-language-model-llm-on-a-custom-dataset-with-qlora-fb60abdeba07>
- de Waegeneer, S. (2022, oktober 11). *AutoClicker*. Verkregen mei 20, 2024, van <https://github.com/samdw6/AutoClicker>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.
- Doxygen. (2023, december 25). *Code Documentation Automated. Free, open source, cross-platform*. (Versie 1.10.0). <https://www.doxygen.nl/>
- ElHousieny, R. (2023, november 19). *Demystifying Tokenization: Preparing Data for Large Language Models (LLMs)*. <https://www.linkedin.com/pulse/demystifying-tokenization-preparing-data-large-models-rany-2nebc/>
- Gallant, A., & Hils, M. (2023). *pdoc: Auto-generate API documentation for Python projects* (Versie 14.1.0). <https://pdoc.dev/>
- Gao, H., Treude, C., & Zahedi, M. (2023). Evaluating Transfer Learning for Simplifying GitHub READMEs. *Proceedings of the 31st ACM Joint European Software En-*

- gineering Conference and Symposium on the Foundations of Software Engineering, 1548–1560. <https://doi.org/10.1145/3611643.3616291>
- GeeksforGeeks (Red.). (2023, augustus 7). *Python Docstrings*. Verkregen mei 19, 2024, van <https://www.geeksforgeeks.org/python-docstrings/>
- Google (Red.). (2023, augustus 8). *Prompt Engineering for Generative AI*. Verkregen mei 19, 2024, van <https://developers.google.com/machine-learning/resources/prompt-eng>
- Google. (2024). *Welcome to the Gemini era*. <https://deepmind.google/technologies/gemini/#introduction>
- Google Python Team. (2024, februari 12). *Google Python Style Guide*. Verkregen mei 9, 2024, van <https://google.github.io/styleguide/pyguide.html>
- Hashemi-Pour, C., & Lutkevich, B. (2024, februari). *BERT language model*. <https://www.techtarget.com/searchenterpriseai/definition/BERT-language-model>
- Hendrycks, D., Burns, C., Basart, S., Zou, A., Mazeika, M., Song, D., & Steinhardt, J. (2020). Measuring Massive Multitask Language Understanding. *CoRR*, abs/2009.03300. <https://arxiv.org/abs/2009.03300>
- Hoque, M. (2023, april 30). *A Comprehensive Overview of Transformer-Based Models: Encoders, Decoders, and More*. <https://medium.com/@minh.hoque/a-comprehensive-overview-of-transformer-based-models-encoders-decoders-and-more-e9bc0644a4e5>
- Iyer, S., Konstas, I., Cheung, A., & Zettlemoyer, L. (2016, augustus). Summarizing Source Code using a Neural Attention Model. In K. Erk & N. A. Smith (Red.), *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 2073–2083). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P16-1195>
- Lambert, N., Castricato, L., von Werra, L., & Havrilla, A. (2022, december 9). *Illustrating Reinforcement Learning from Human Feedback (RLHF)*. <https://huggingface.co/blog/rlhf>
- McBurney, P. W., & McMillan, C. (2014). Automatic Documentation Generation via Source Code Summarization of Method Context. *Proceedings of the 22nd International Conference on Program Comprehension*, 279–290. <https://doi.org/10.1145/2597008.2597149>
- Meta. (2024). *Llama 2: open source, free for research and commercial use*. <https://llama.meta.com/>
- Microsoft (Red.). (2024). *Azure OpenAI Service*. Verkregen mei 21, 2024, van <https://azure.microsoft.com/en-us/products/ai-services/openai-service>
- OpenAI. (2023). *GPT-4 Technical Report*.
- OpenAi. (2024a). *Models*. Verkregen mei 9, 2024, van <https://platform.openai.com/docs/models/overview>

- OpenAi (Red.). (2024b). *Prompt Engineering*. Verkregen mei 19, 2024, van <https://platform.openai.com/docs/guides/prompt-engineering>
- Peckham, S., Day, J., & hbr, D. (2024, januari 30). *Recommendations for LLM fine-tuning*. Verkregen mei 19, 2024, van <https://learn.microsoft.com/en-us/ai/playbook/technology-guidance/generative-ai/working-with-llms/fine-tuning-recommend?source=recommendations>
- Pedrido, M. O. (2023, oktober 27). *gpt4docstrings*. <https://github.com/MichaelisTrofficus/gpt4docstrings>
- Procko, T., & Collins, S. (2023). Automatic Code Documentation with Syntax Trees and GPT: Alleviating Software Development's Most Redundant Task. <https://doi.org/10.2139/ssrn.4571367>
- Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving Language Understanding by Generative Pre-Training. https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf
- Rozière, B., Gehring, J., Gloeckle, F., Sootla, S., Gat, I., Tan, X. E., Adi, Y., Liu, J., Sauvestre, R., Remez, T., Rapin, J., Kozhevnikov, A., Evtimov, I., Bitton, J., Bhatt, M., Ferrer, C. C., Grattafiori, A., Xiong, W., Défossez, A., ... Synnaeve, G. (2024). Code Llama: Open Foundation Models for Code.
- Simmons, L. (2019, maart 12). *bmi-project*. Verkregen mei 20, 2024, van <https://github.com/lsimmons2/bmi-project>
- Sphinx Team. (2023). *Sphinx* (Versie 7.2.6). <https://www.sphinx-doc.org/>
- Sridhara, G., Hill, E., Muppaneni, D., Pollock, L., & Vijay-Shanker, K. (2010). Towards Automatically Generating Summary Comments for Java Methods. *Proceedings of the 25th IEEE/ACM International Conference on Automated Software Engineering*, 43–52. <https://doi.org/10.1145/1858996.1859006>
- Stöffelbauer, A. (2023, oktober 24). *How Large Language Models work*. <https://medium.com/data-science-at-microsoft/how-large-language-models-work-91c362f5b78f>
- swimm.io (Red.). (2024). *Code documentation: benefits, challenges, and tips for success*. Swimm Team. <https://swimm.io/learn/code-documentation/code-documentation-benefits-challenges-and-tips-for-success#:~:text=Code%20documentation%20is%20a%20collection,size%20of%20documentation%20can%20vary>
- TeeTracker. (2023, augustus 24). *LLM fine-tuning step: Tokenizing*. <https://teetracker.medium.com/llm-fine-tuning-step-tokenizing-caebb280cfc2>
- The Graphviz Authors. (2024). *Graphviz*. Verkregen mei 19, 2024, van <https://www.graphviz.org/>
- TIOBE (Red.). (2024, mei 1). *TIOBE Index for May 2024*. Verkregen mei 19, 2024, van <https://www.tiobe.com/tiobe-index/>

- Trad, F., Chapman, J., Ludolf, J., Gaston, R., & Harper, C. (2024). *ChatGPT Prompt Engineering for Developers: Advanced Prompt Engineering Strategies*. Verkregen mei 21, 2024, van <https://campus.datacamp.com/courses/chatgpt-prompt-engineering-for-developers>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need.
- West Health Institute Revision. (2018). *Pyvis*. Verkregen mei 9, 2024, van <https://pyvis.readthedocs.io/en/latest/>
- What are the primary advantages of transformer models?* (2023, november 6). <https://aiml.com/what-are-the-main-advantages-of-the-transformer-models/>